Initiation aux logiciels R et RStudio

Pour l'analyse de données et les représentations graphiques

Benoît Simon-Bouhet

Conservatoire Botanique National

9, 10 et 11 décembre 2024

Le tidyverse : vue d'ensemble

Les grands principes

C'est quoi les "Data Sciences" ?

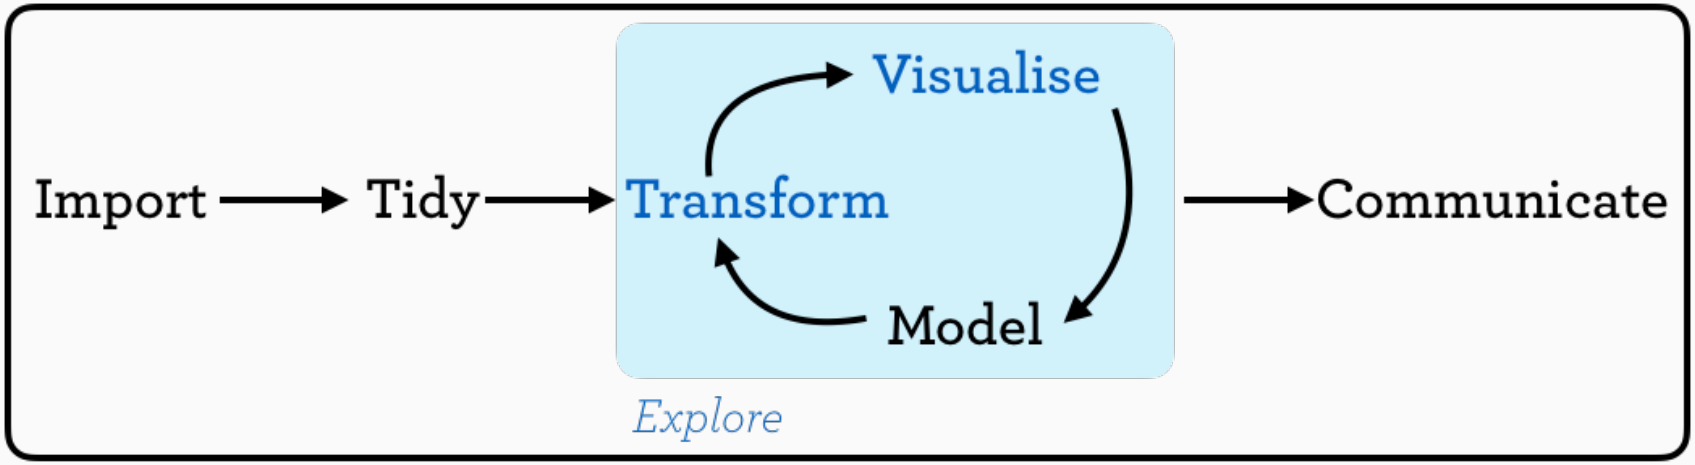

Import :

- readr
- readxl
- haven
- httr
- rvest
- xml2

Les grands principes

C'est quoi les "Data Sciences" ?

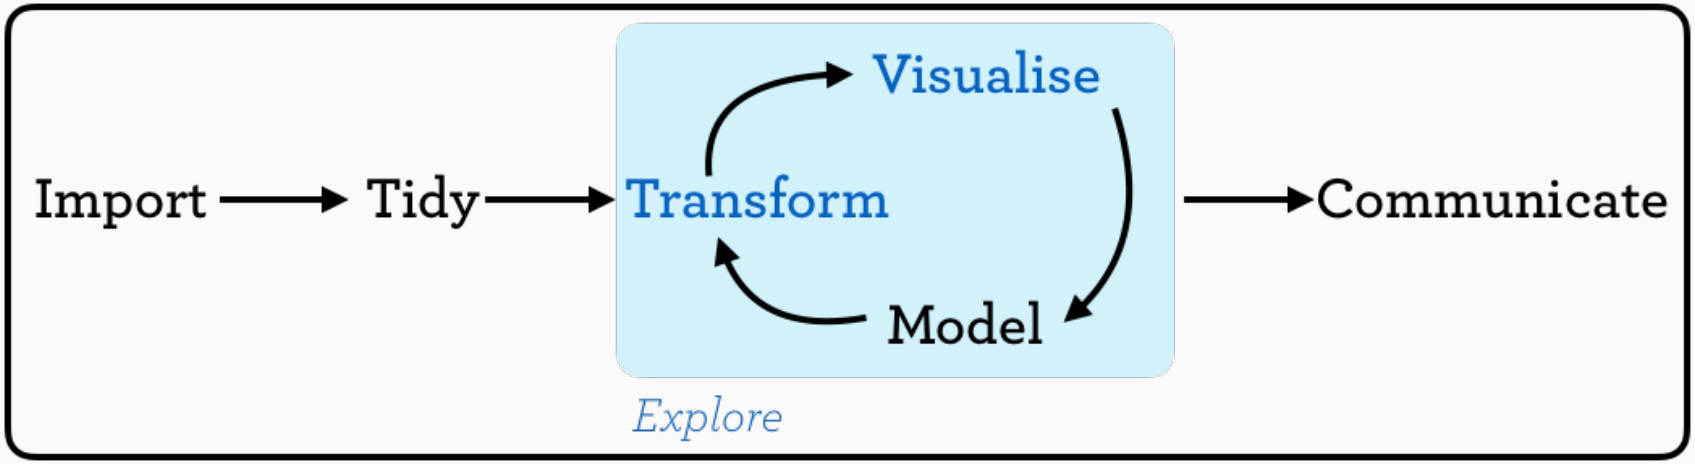

Tidy :

- tibble
- tidyr

Les grands principes

C'est quoi les "Data Sciences" ?

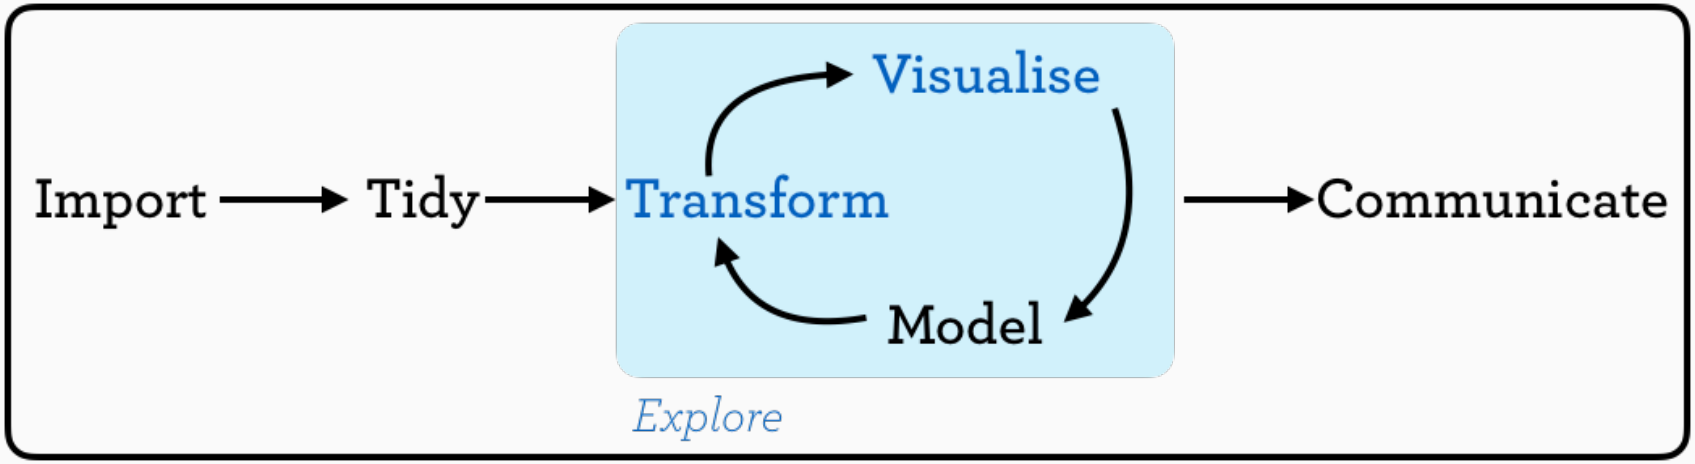

Transform :

- dplyr
- forcats
- hms
- lubridate
- stringr

Les grands principes

C'est quoi les "Data Sciences"?

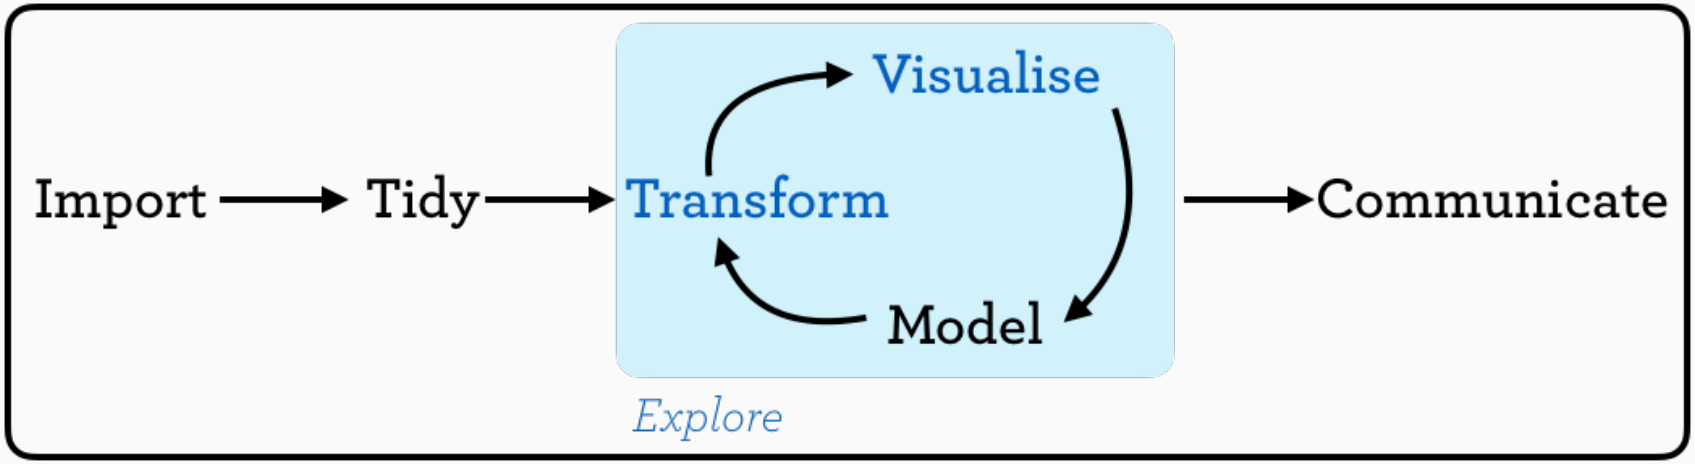

Visualise :

- ggplot2

Les grands principes

C'est quoi les "Data Sciences" ?

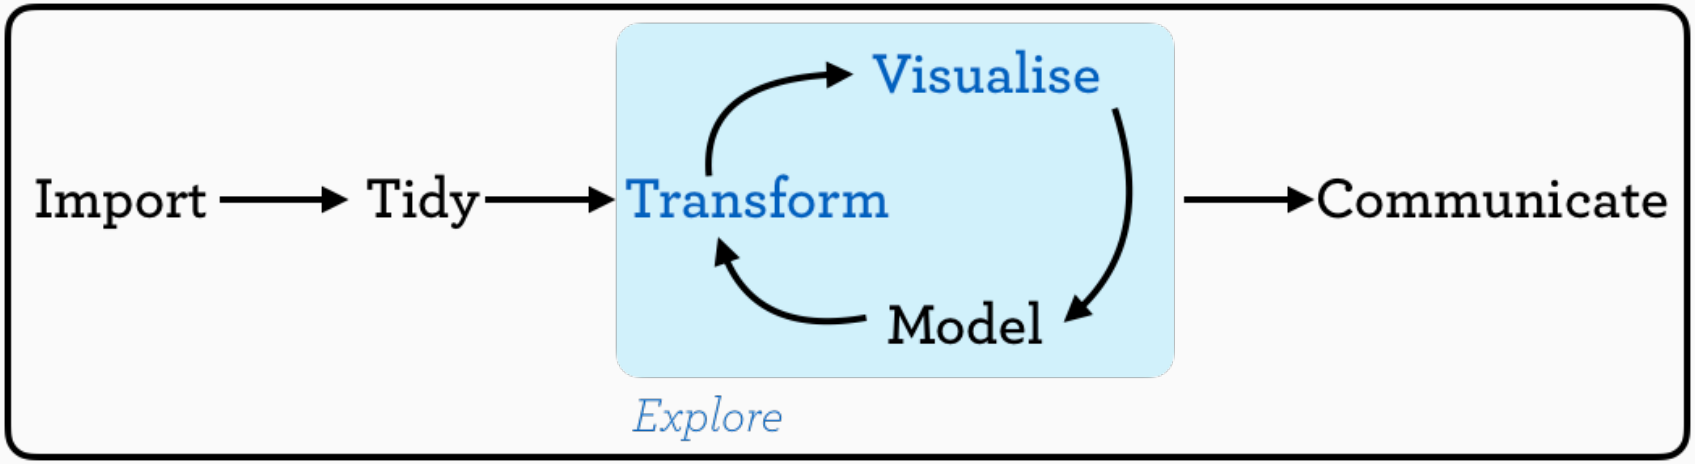

Model :

- broom
- modelr

Les grands principes

C'est quoi les "Data Sciences"?

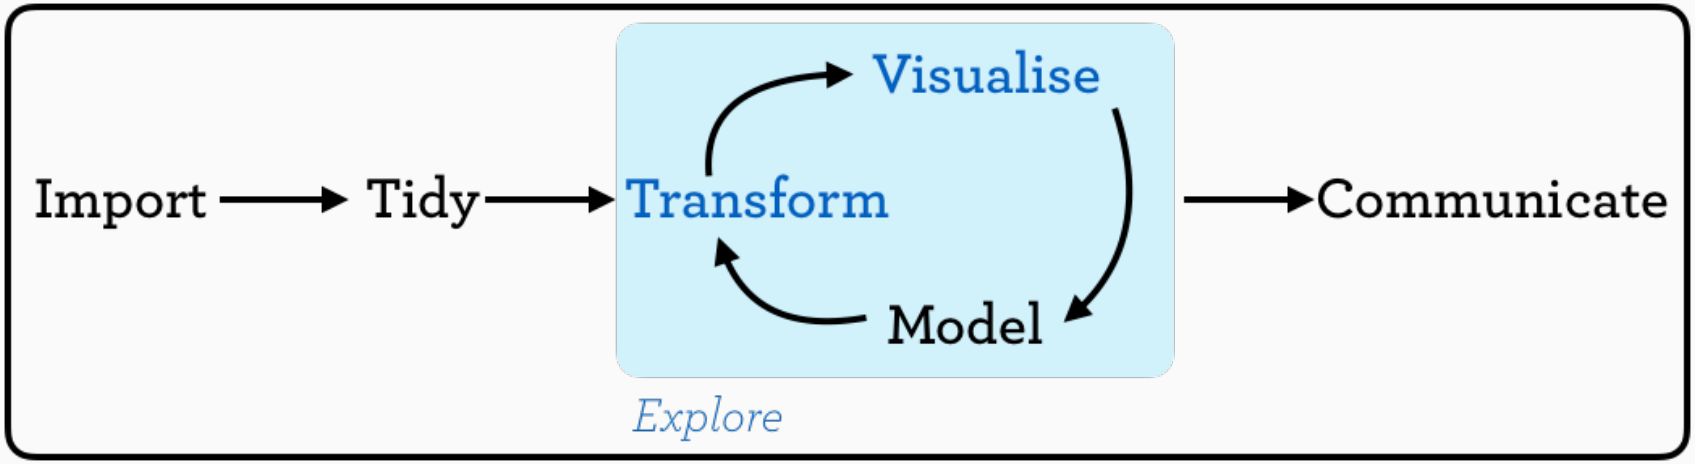

Communicate :

- knitr
- rmarkdown
- blogdown
- bookdown
- shiny

Les grands principes

C'est quoi les "Data Sciences"?

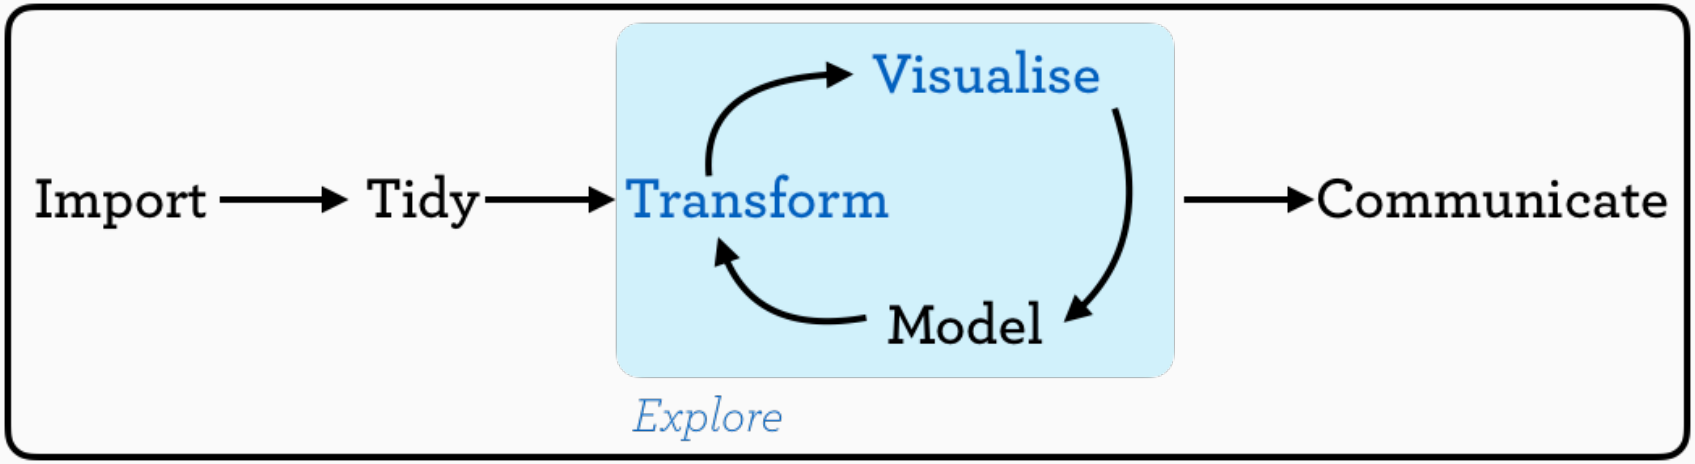

Program :

- purrr
- magritr

Visualisation : 1. La grammaire des graphiques

1. La grammaire des graphiques

Installation des packages nécessaires

```
## install.packages("tidyverse")
## install.packages("nycflights13")
library(tidyverse)
library(nycflights13)
```

1. La grammaire des graphiques

Principes du package ggplot2

Pour faire un graphique avec ggplot2, il nous faut au moins les 3 ingrédients suivants :

- **data** : le nom d'un tableau contenant les données
- **geom** : les objets géométriques que l'on souhaite voir apparaître sur le graphique (des points, des lignes, des boites à moustache...)
- **aes** : les attributs esthétiques des objets géométriques (position, taille, couleur, transparence...)

1. La grammaire des graphiques

Les données

Le tableau `flights` du package `nycflights13` :

```
flights

# A tibble: 336,776 x 19
    year month   day dep_time sched_dep_time dep_delay arr_time
   <int> <int> <int>    <int>          <int>     <dbl>    <int>
 1  2013     1     1      517            515         2      830
 2  2013     1     1      533            529         4      850
 3  2013     1     1      542            540         2      923
 4  2013     1     1      544            545        -1     1004
 5  2013     1     1      554            600        -6      812
 6  2013     1     1      554            558        -4      740
 7  2013     1     1      555            600        -5      913
 8  2013     1     1      557            600        -3      709
 9  2013     1     1      557            600        -3      838
10  2013     1     1      558            600        -2      753
# i 336,766 more rows
# i 12 more variables: sched_arr_time <int>, arr_delay <dbl>,
#   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>,
#   dest <chr>, air_time <dbl>, distance <dbl>, hour <dbl>,
#   minute <dbl>, time_hour <dttm>
```

1. La grammaire des graphiques

Les données

Dans un premier temps nous travaillerons uniquement avec les vols de la compagnie Alaska Airlines :

```
# On filtre les données de la compagnie AS
alaska_flights <- flights %>%
  filter(carrier == "AS")
```

```
# On s'assure qu'on a un tableau beaucoup plus petit
dim(alaska_flights)
```

```
[1] 714  19
```

1. La grammaire des graphiques

Premier graphique

Les retards des vols au décollage et à l'aterrissage sont-ils liés ?

```
ggplot(data = alaska_flights,
       mapping = aes(x = dep_delay, y = arr_delay))
```

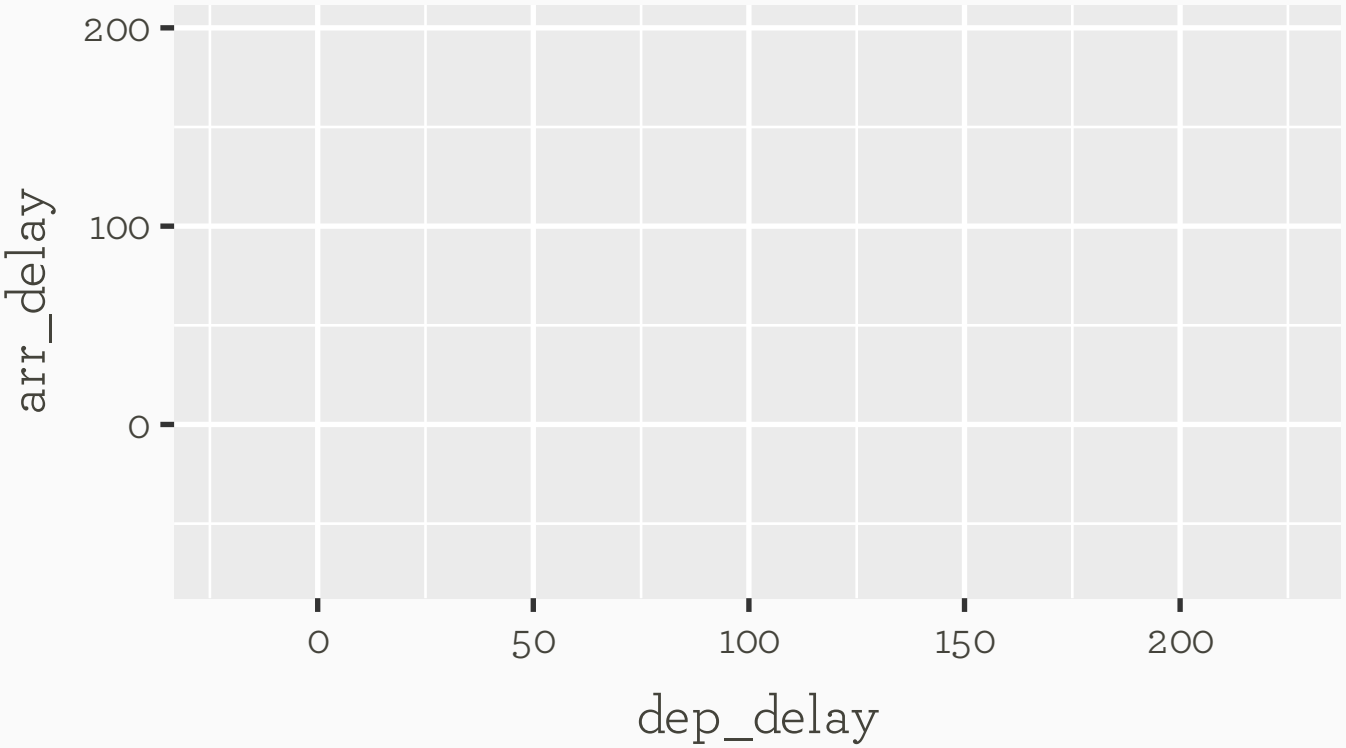

1. La grammaire des graphiques

Premier graphique

```
ggplot(data = alaska_flights,
       mapping = aes(x = dep_delay, y = arr_delay)) +
  geom_point()
```

```
Warning: Removed 5 rows containing missing values or values
outside the scale
range (`geom_point()`).
```

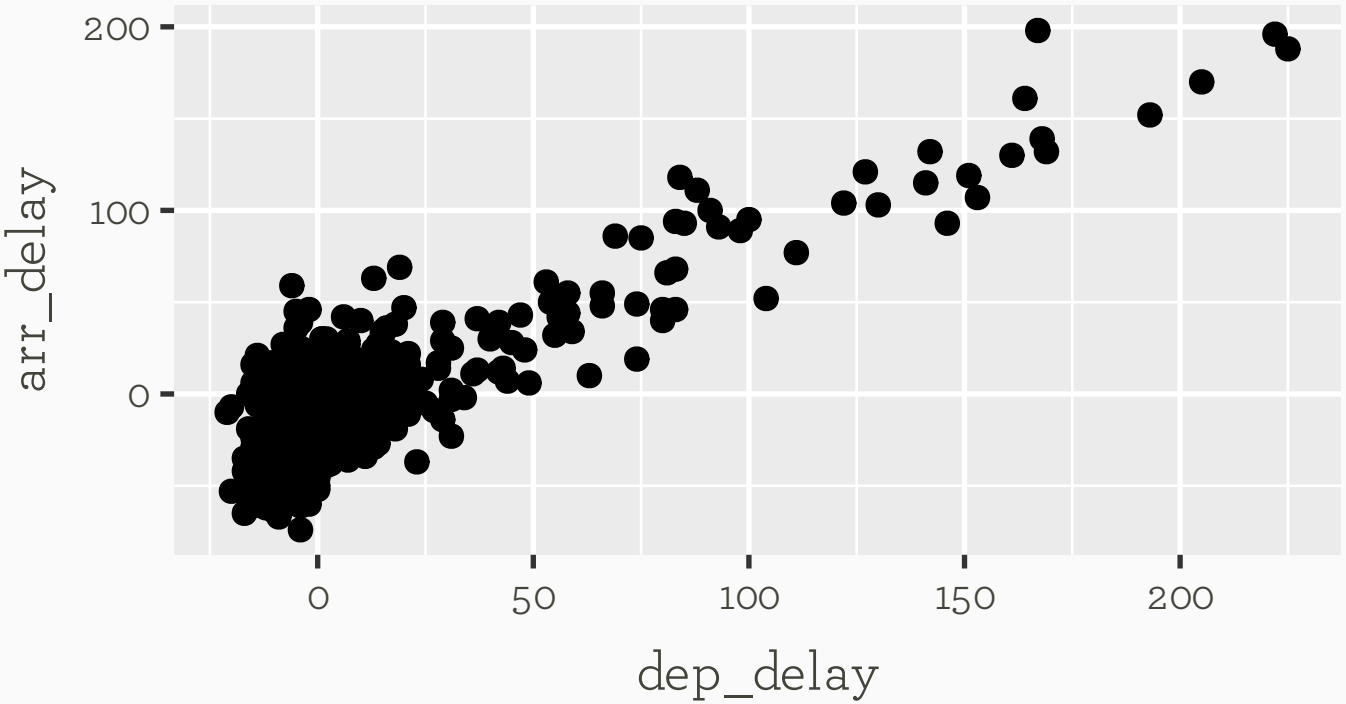

1. La grammaire des graphiques

Premier graphique

On peut se passer du nom des arguments `data` et `mapping` :

```
ggplot(alaska_flights, aes(x = dep_delay, y = arr_delay)) +
  geom_point()
```

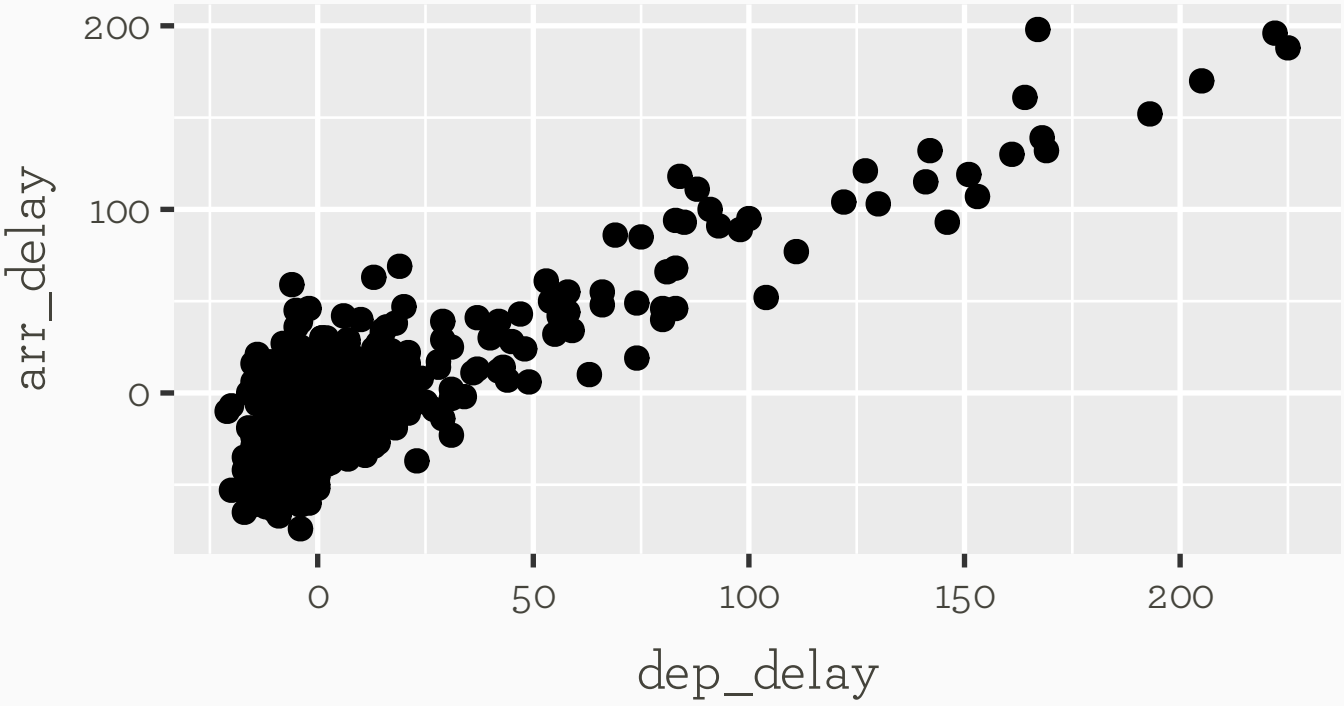

Visualisation :
2. Nuages de points

2. Nuages de points

geom_point()

Les nuages de points sont créés grâce à la fonction `geom_point()` qui ajoute au graphique une couche contenant l'objet géométrique "points" :

```
ggplot(alaska_flights, aes(x = dep_delay, y = arr_delay)) +
  geom_point()
```

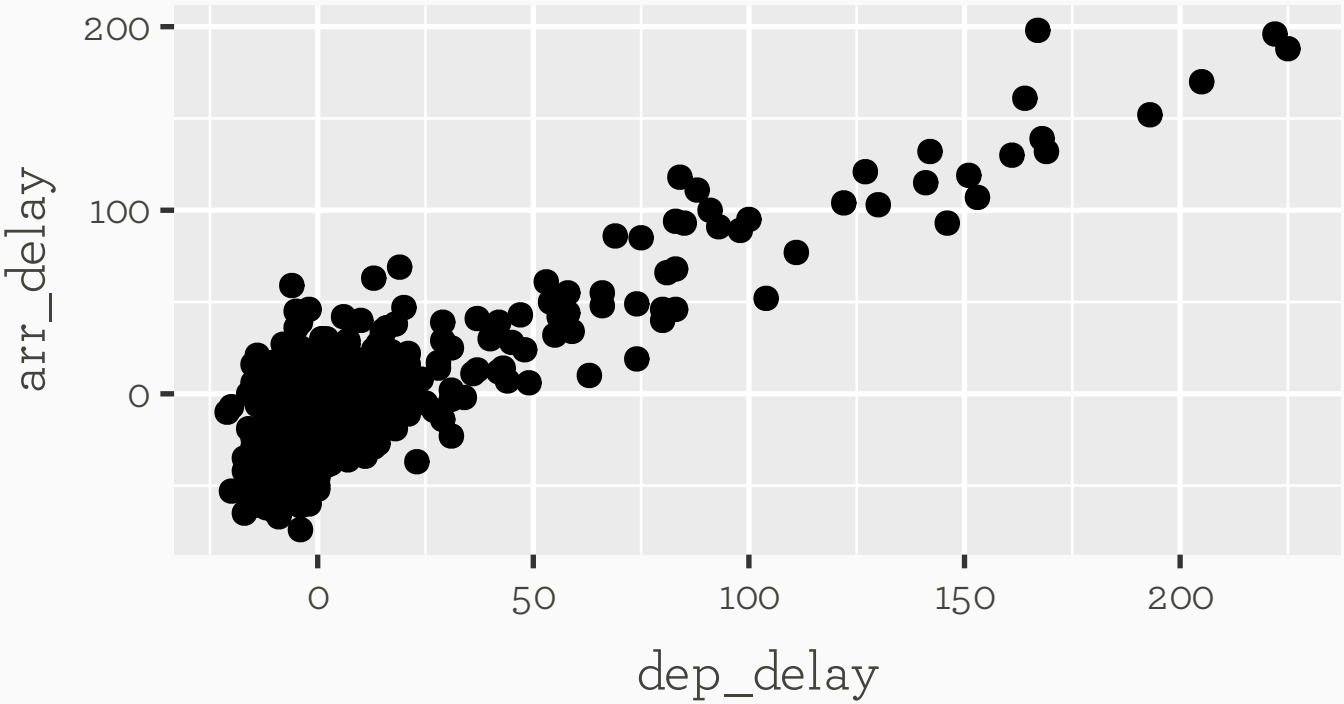

2. Nuages de points

Overplotting

Lorsque de nombreux points se superposent, on peut améliorer l'aspect du graphique en jouant sur la transparence des points :

```
ggplot(alaska_flights, aes(x = dep_delay, y = arr_delay)) +
  geom_point(alpha = 0.1)
```

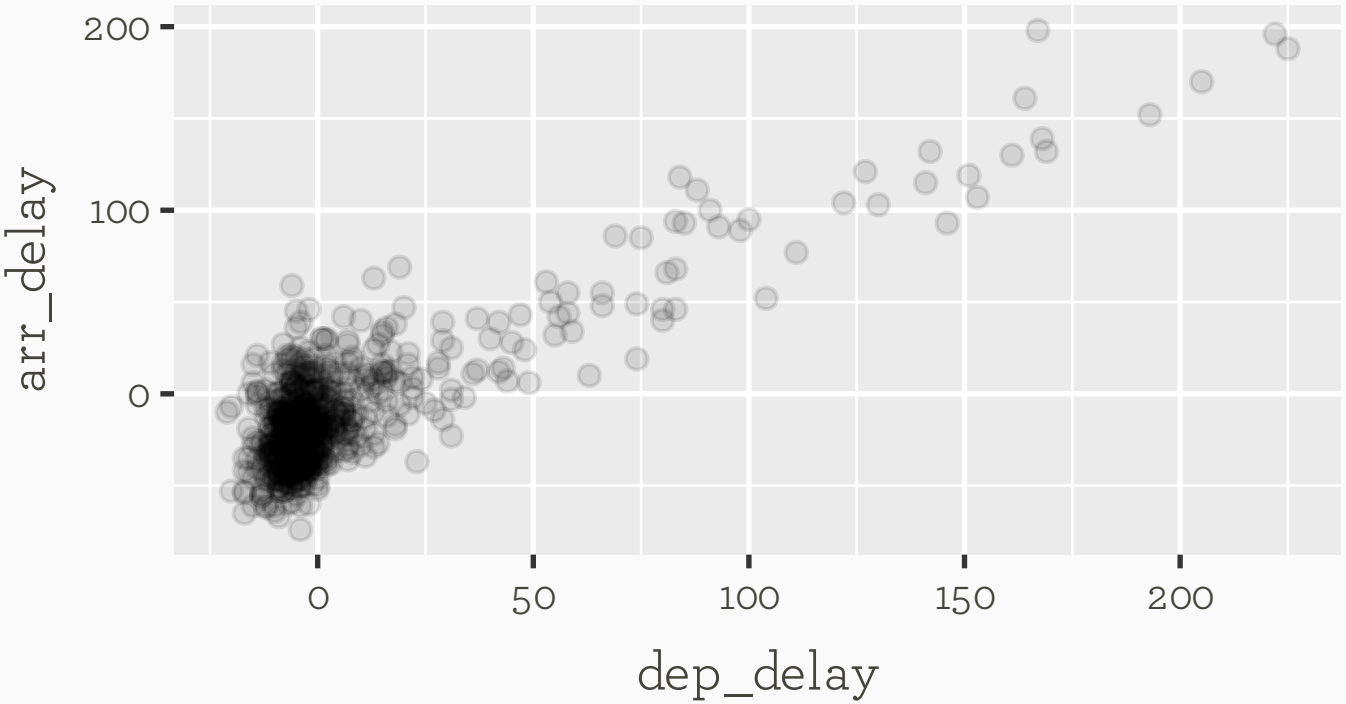

2. Nuages de points

Overplotting

Lorsque de nombreux points se superposent, on peut améliorer l'aspect du graphique en jouant sur la taille des points :

```
ggplot(alaska_flights, aes(x = dep_delay, y = arr_delay)) +
  geom_point(size = 0.4)
```

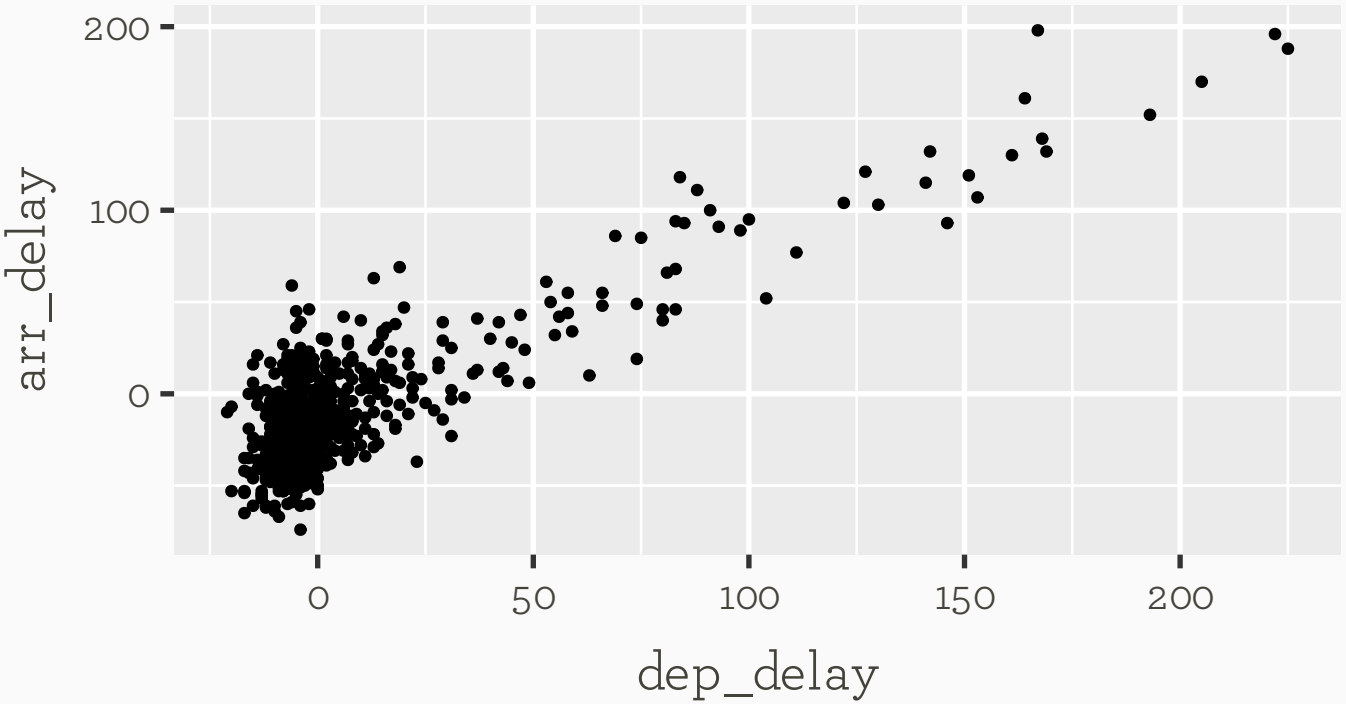

2. Nuages de points

Overplotting

Lorsque de nombreux points se superposent, on peut améliorer l'aspect du graphique en jouant sur le symbole utilisé :

```
ggplot(alaska_flights, aes(x = dep_delay, y = arr_delay)) +
  geom_point(shape = 1)
```

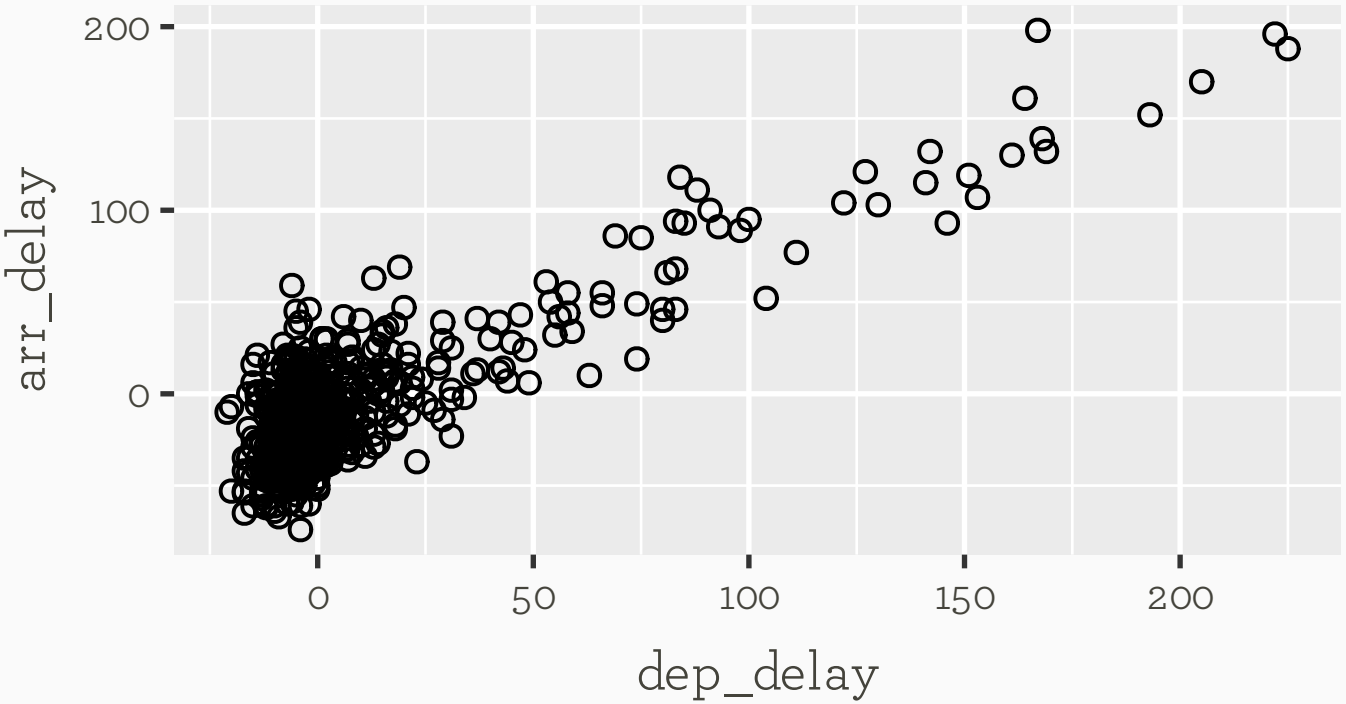

2. Nuages de points

Overplotting

Il est bien sûr possible de combiner plusieurs modifications :

```
ggplot(alaska_flights, aes(x = dep_delay, y = arr_delay)) +
  geom_point(alpha = 0.4, size = 0.6, shape = 1)
```

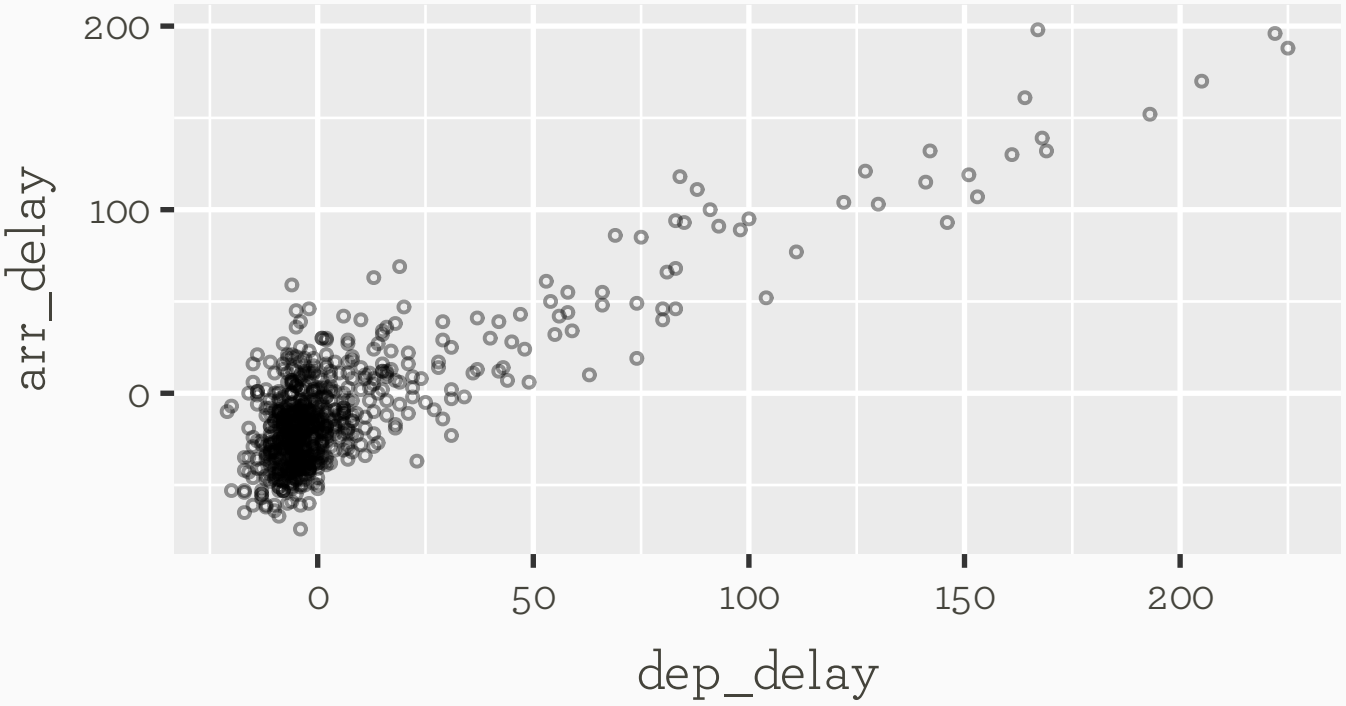

2. Nuages de points

Overplotting

Il est enfin possible de modifier la couleur des points :

```
ggplot(alaska_flights, aes(x = dep_delay, y = arr_delay)) +
  geom_point(alpha = 0.4, size = 0.6,
             shape = 1, color = "darkorchid")
```

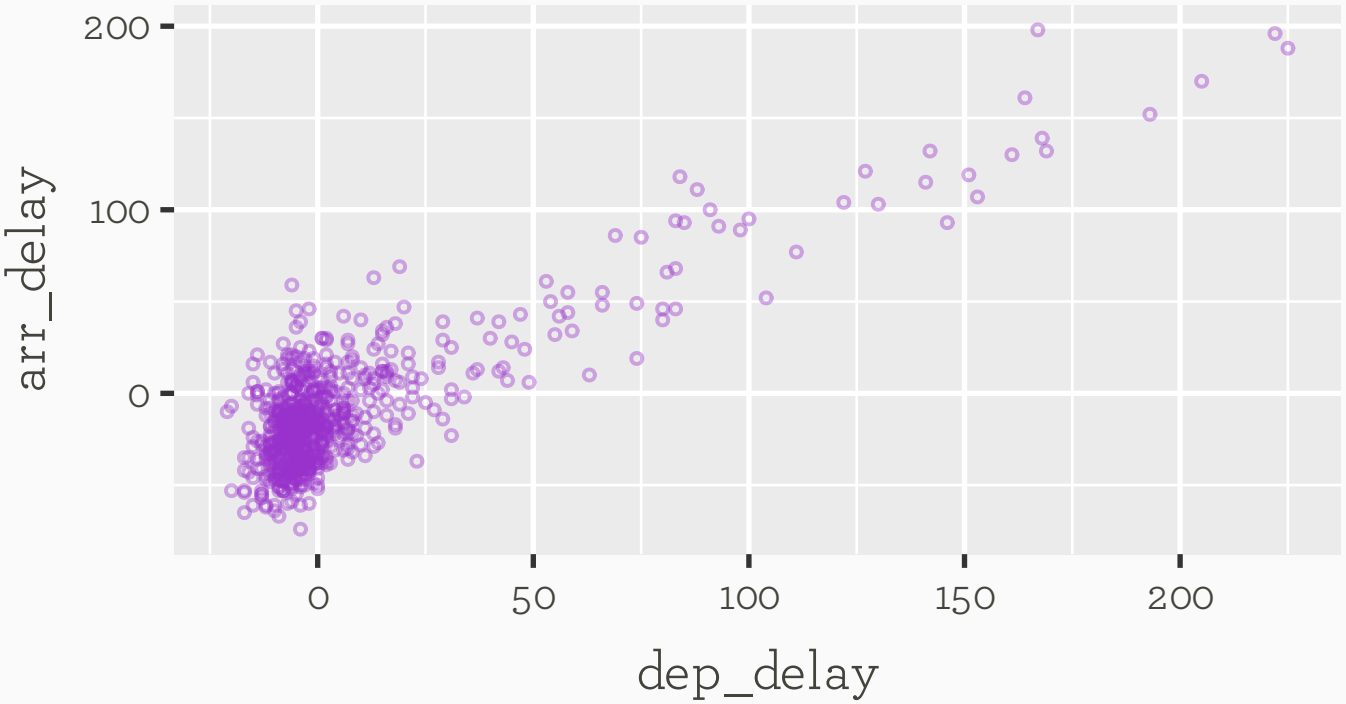

2. Nuages de points

Overplotting

Pour certains symboles, on fait la distinction entre couleur de contour et de remplissage :

```
ggplot(alaska_flights, aes(x = dep_delay, y = arr_delay)) +
  geom_point(size = 0.6, shape = 21,
             fill = "dodgerblue", color = "firebrick")
```

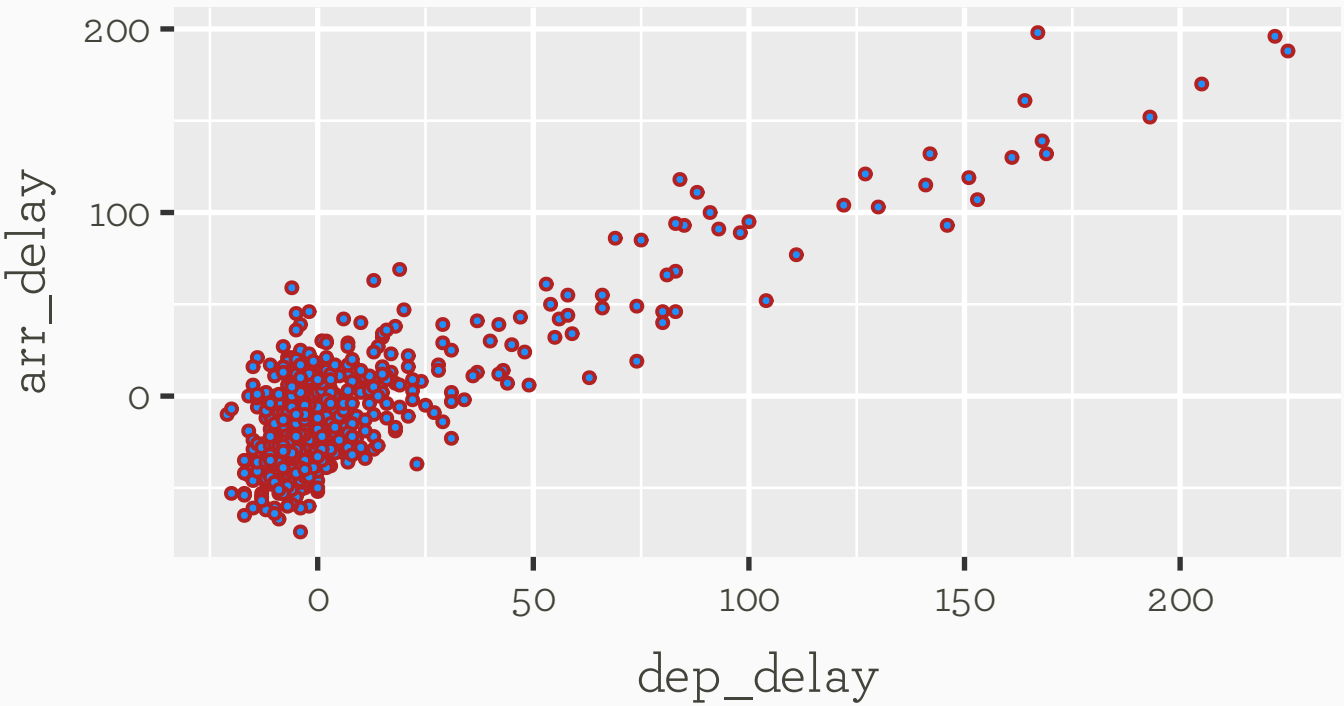

2. Nuages de points

Aesthetic mappings

Toutes ces options peuvent être associées à des variables :

```
ggplot(alaska_flights, aes(x = dep_delay, y = arr_delay,
                           color = air_time)) +
  geom_point()
```

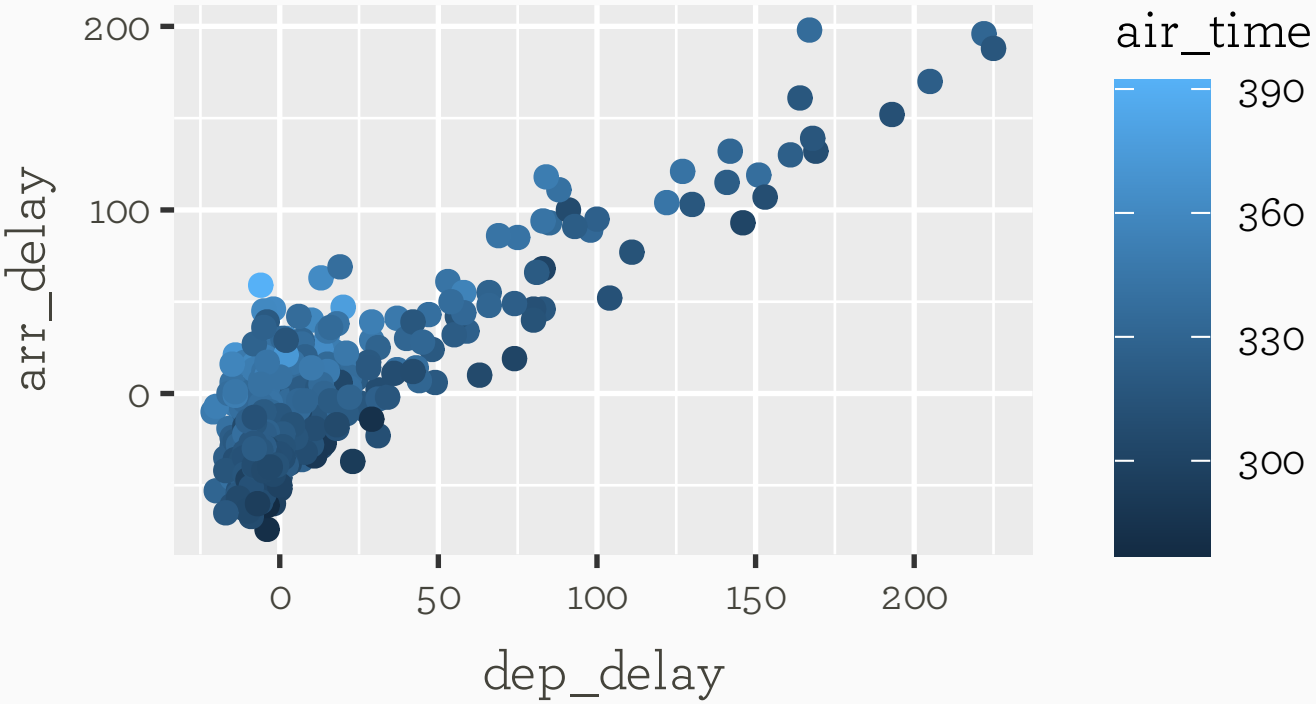

2. Nuages de points

Aesthetic mappings

Est-ce que le jour de la semaine a une influence sur les retards des vols ?

```
library(lubridate)
alaska_small <- alaska_flights %>%
  mutate(jour = wday(time_hour,
                     label = TRUE,
                     abbr = TRUE,
                     week_start = 1)) %>%
  select(dep_delay, arr_delay, jour)
```

2. Nuages de points

Aesthetic mappings

Est-ce que le jour de la semaine a une influence sur les retards des vols ?

2. Nuages de points

Aesthetic mappings

Est-ce que le jour de la semaine a une influence sur les retards des vols ?

```
alaska_small

# A tibble: 714 x 3
   dep_delay arr_delay jour
       <dbl>     <dbl> <ord>
 1        -1       -10 Mar
 2        -7       -19 Mar
 3        -3       -41 Mer
 4         3         1 Mer
 5        -1       -18 Jeu
 6         2        -9 Jeu
 7         0         1 Ven
 8        -7       -29 Ven
 9         0       -19 Sam
10       -12       -12 Sam
# i 704 more rows
```

2. Nuages de points

Aesthetic mappings

```
ggplot(alaska_small,
       aes(x = dep_delay, y = arr_delay, color = jour)) +
  geom_point()
```

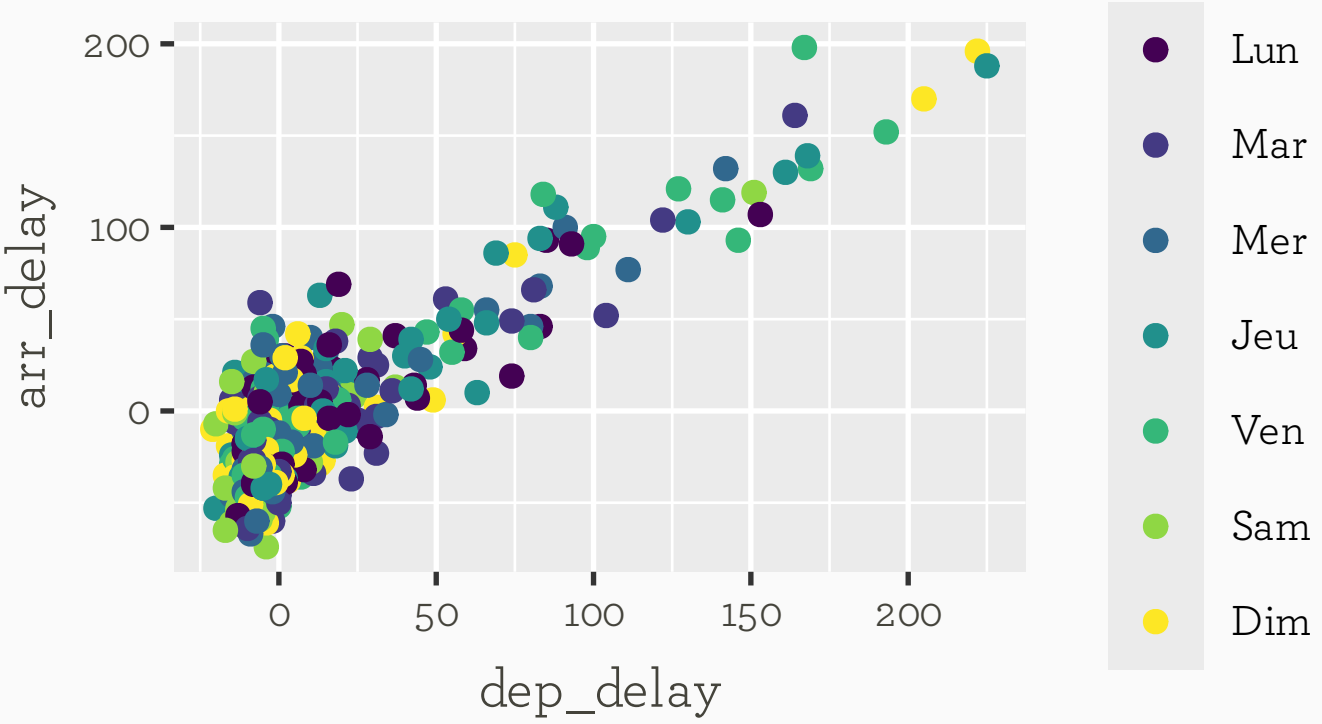

2. Nuages de points

Aesthetic mappings

Les aesthetics possibles sont donc :

- `x` et `y`
- `color` (ou `colour`)
- `fill`
- `shape`
- `size`
- `alpha`

On peut placer ces arguments :

- Dans la fonction `aes()` pour associer une variable numérique ou catégorielle à ces caractéristiques esthétiques
- En dehors de la fonction `aes()` pour fixer manuellement la valeur voulue.

2. Nuages de points

Aesthetic mappings

Lorsque l'on fixe ces éléments manuellement, il faut fournir des valeur pertinentes :

`color` un nom de couleur, ou un numéro, ou un code hexadécimal, ou hsv, ou rgb, ou...

`size` un nombre de points en millimètres

`alpha` un degré d'opacité, compris entre 0 et 1

`shape` une valeur numérique comprise entre 0 et 24

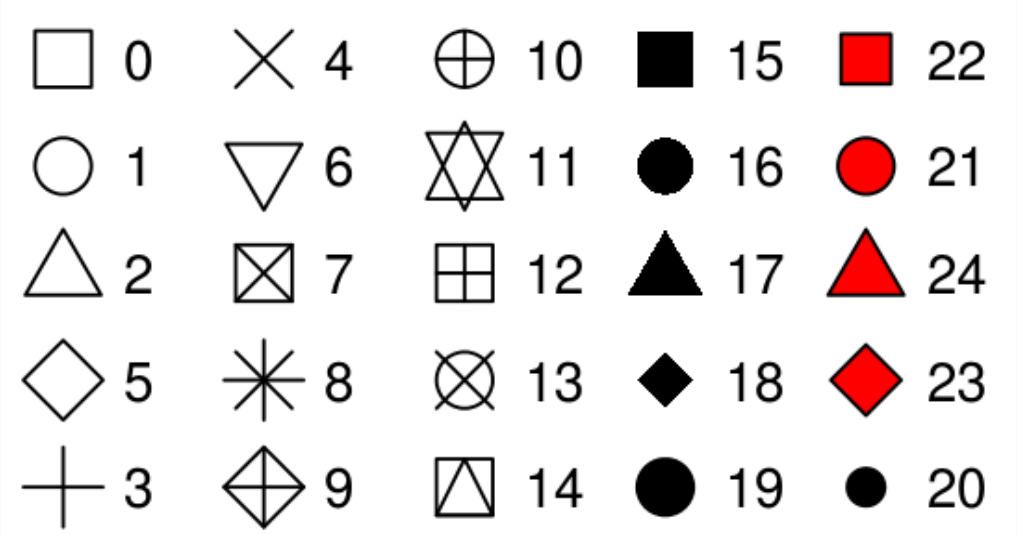

2. Nuages de points

Aesthetic mappings : exercices

Qu'est-ce qui ne va pas avec ce code ? Pourquoi les points ne sont-ils pas bleus ?

```
ggplot(alaska_flights,
       aes(x = dep_delay, y = arr_delay, color = "blue")) +
  geom_point()
```

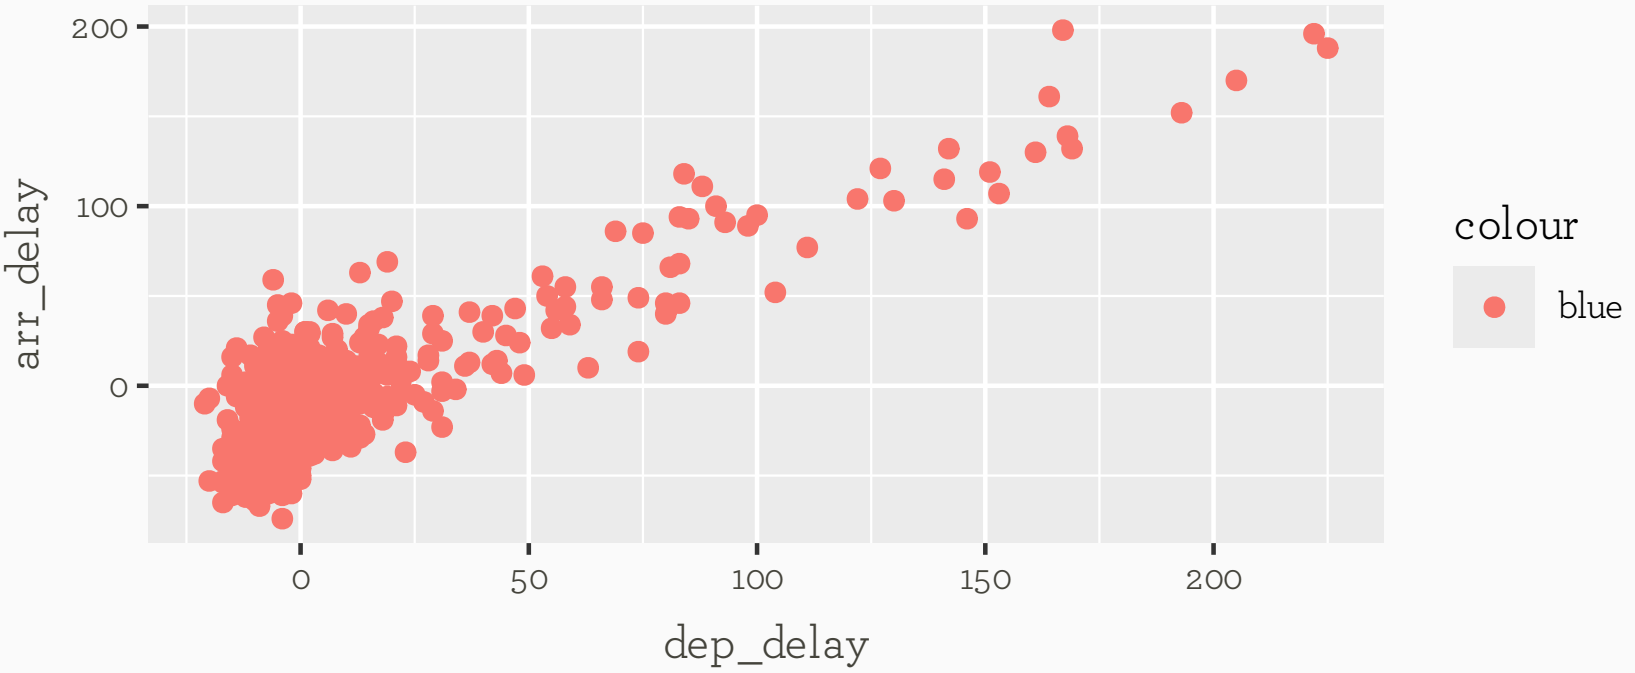

2. Nuages de points

Aesthetic mappings : exercices

Avec les données contenues dans l'objet `dauphin`, faites le graphique suivant :

2. Nuages de points

Aesthetic mappings : exercices

En plus des points, ajoutez une couche supplémentaire à ce graphique en utilisant la fonction `geom_smooth()` :

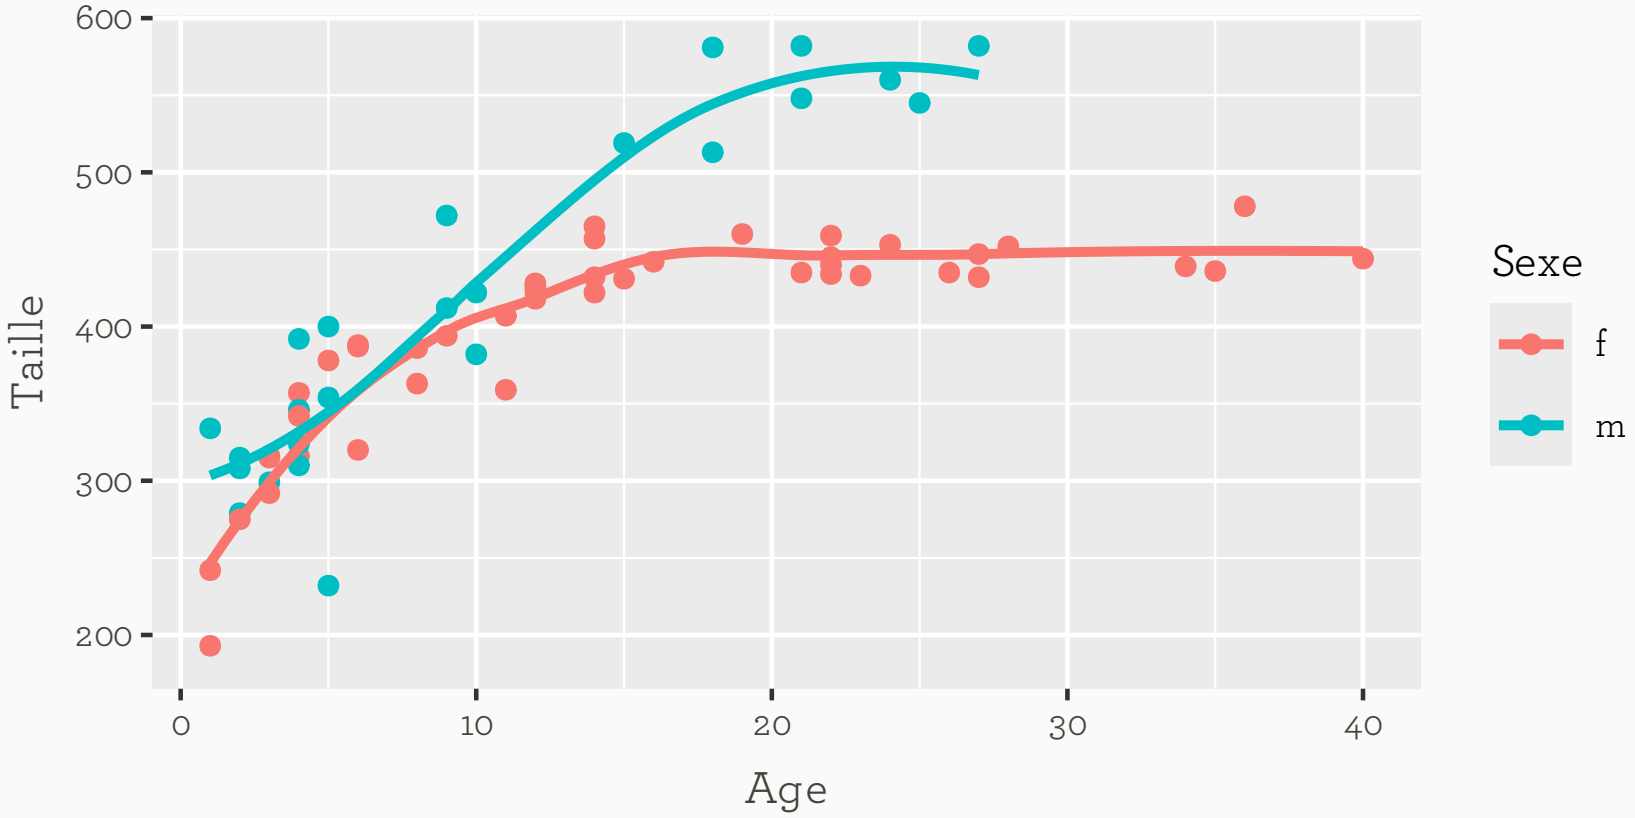

Que mettons-nous en évidence ici ?

2. Nuages de points

Aesthetic mappings : exercices

Toujours avec dauphin, créez maintenant ce nouveau graphique :

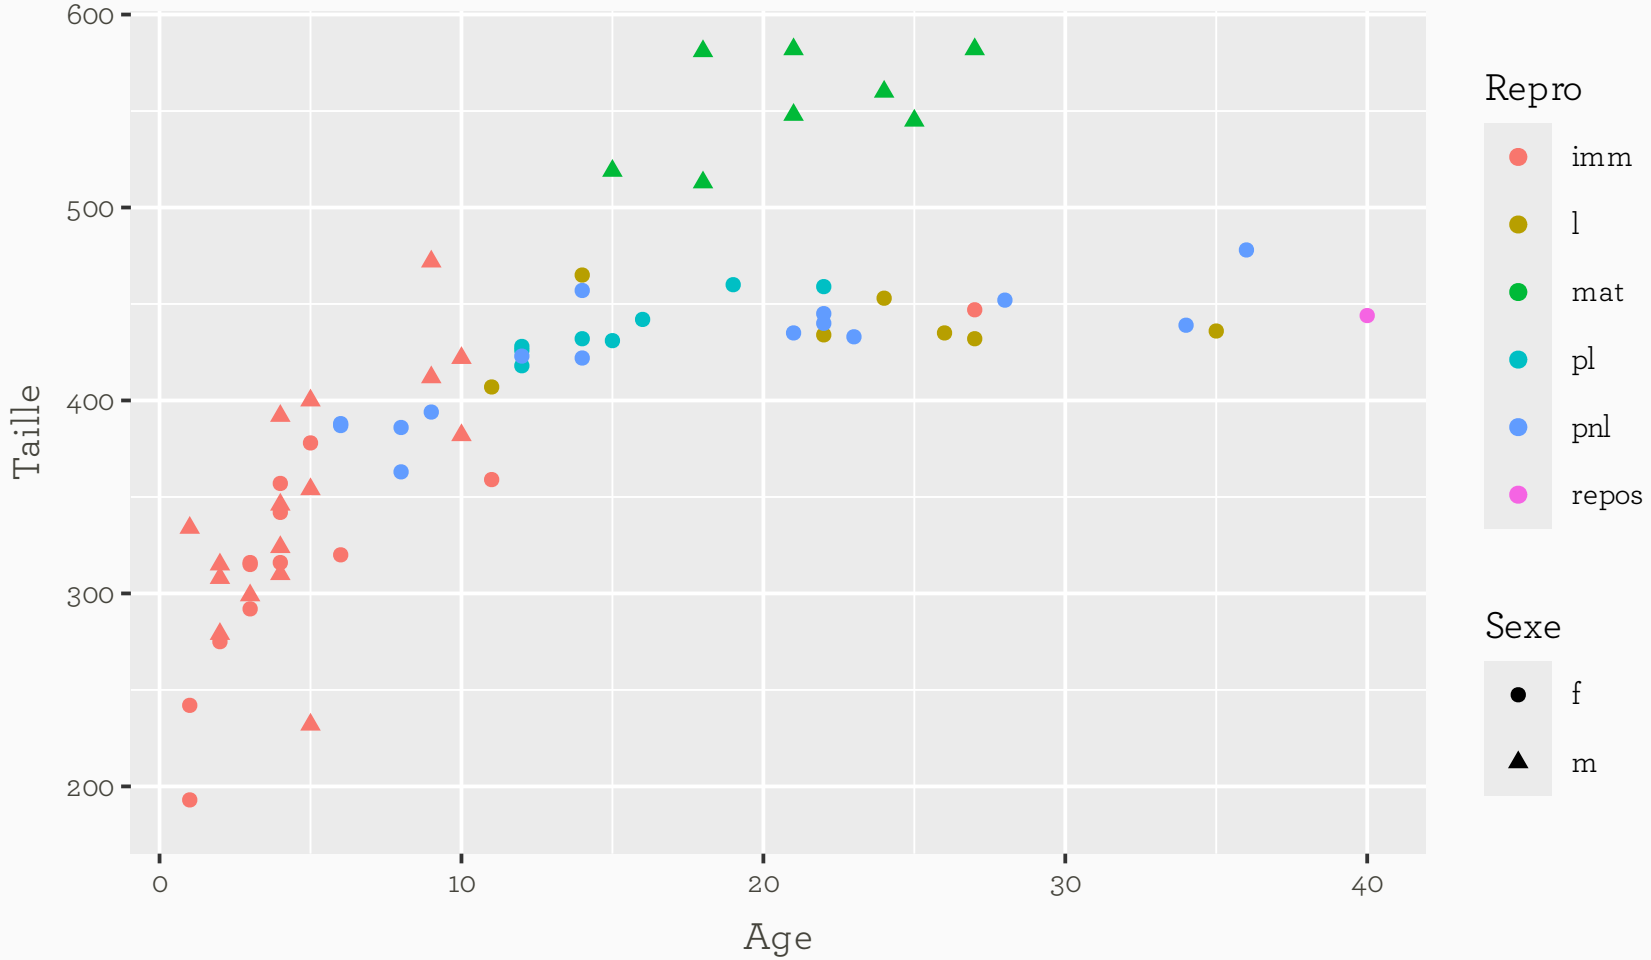

R nous dit qu'il a retiré 25 points. Pourquoi ?

2. Nuages de points

geom_jitter()

To jitter = trembler / être nerveux

```
ggplot(alaska_flights,
       aes(x = factor(month), y = arr_delay)) +
  geom_point()
```

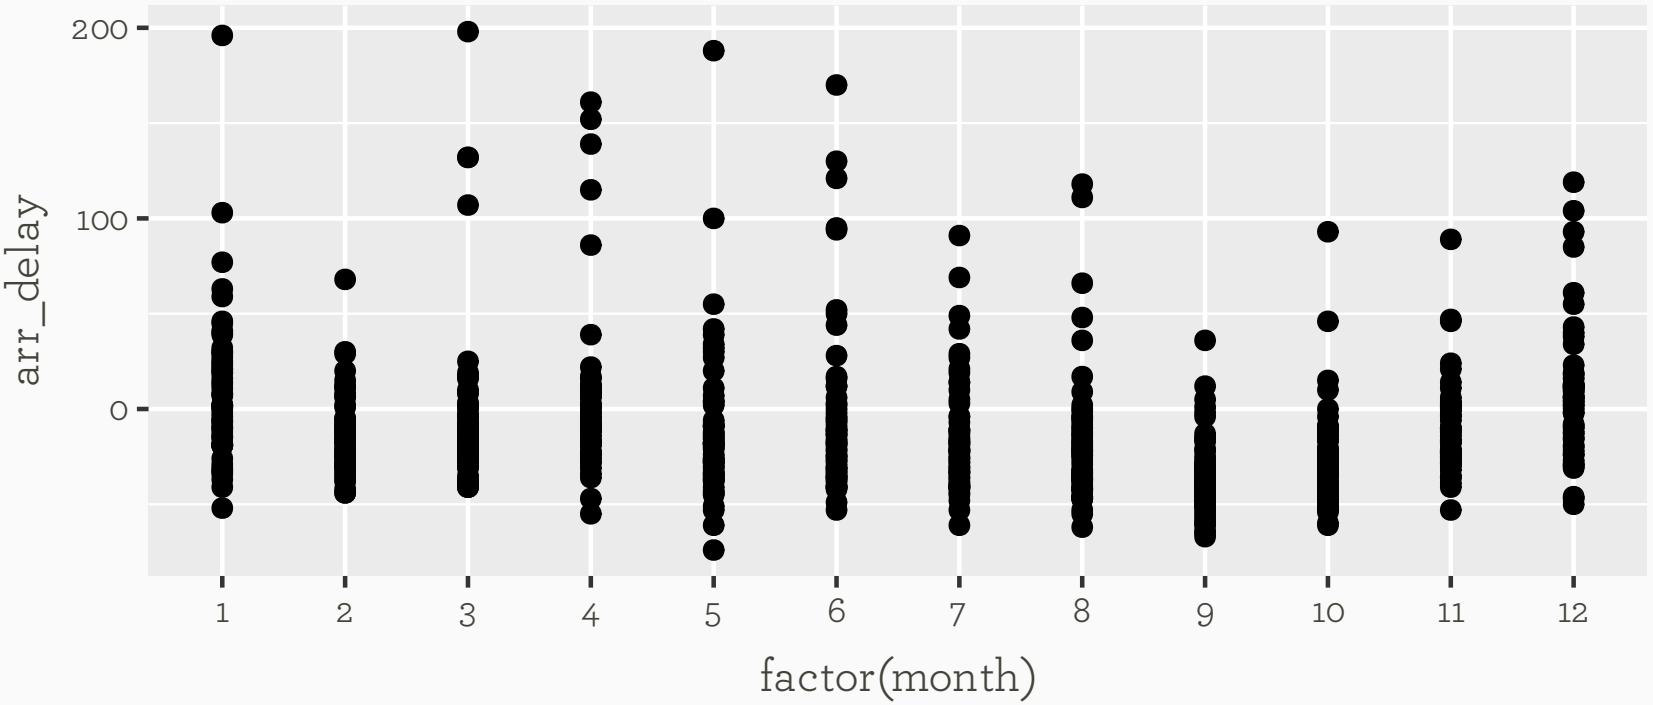

2. Nuages de points

geom_jitter()

To jitter = trembler / être nerveux

```
ggplot(alaska_flights,
       aes(x = factor(month), y = arr_delay)) +
  geom_jitter(height = 0, width = 0.25)
```

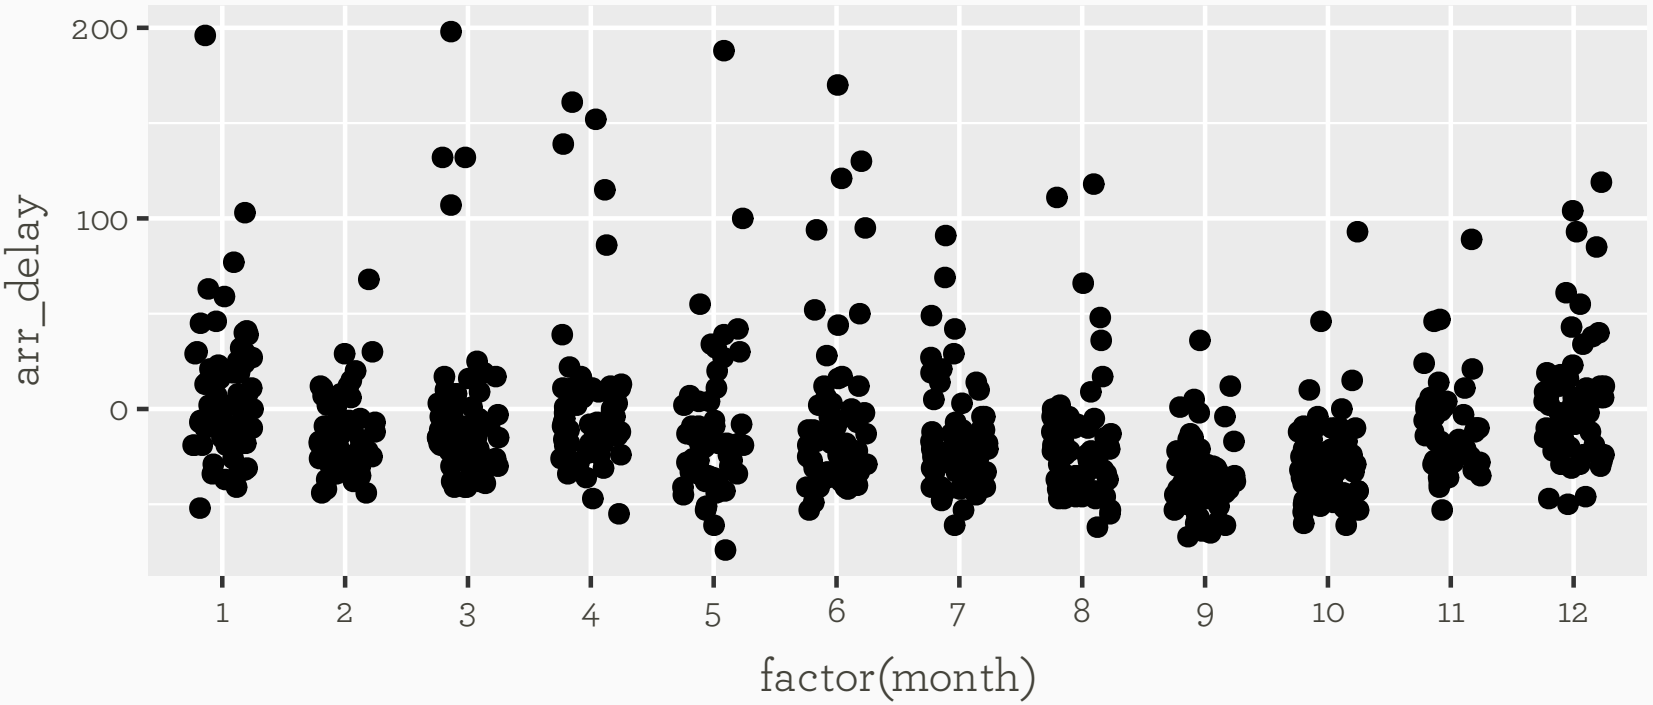

Visualisation :
3. Graphiques en lignes

3. Graphiques en lignes

Données météo

Nous allons maintenant travailler avec le jeu de données `weather` du package `nycflights13`.

- Examinez ce jeu de données
- Quelles sont les variables disponibles

Extraction des données météo de l'aéroport de Newark sur les 15 premiers jours de janvier :

```
small_weather <- weather %>%
  filter(origin == "EWR",
         month == 1,
         day <= 15)
```

3. Graphiques en lignes

`geom_line()`

Températures horaires à l'aéroport de Newark :

```
ggplot(small_weather, aes(x = time_hour, y = temp)) +
  geom_line()
```

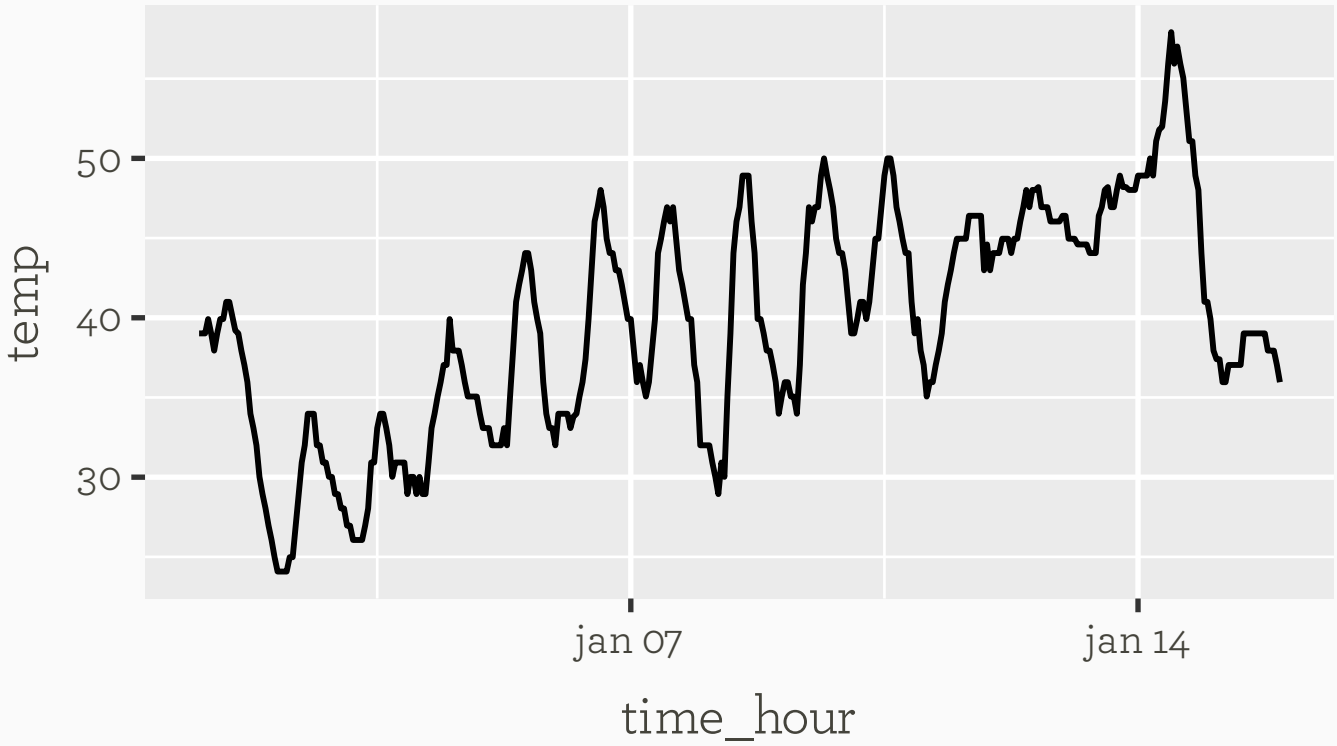

3. Graphiques en lignes

geom_line()

Il est tout à fait possible d'empiler les couches :

```
ggplot(small_weather, aes(x = time_hour, y = temp)) +
  geom_line() +
  geom_point(size = 0.5)
```

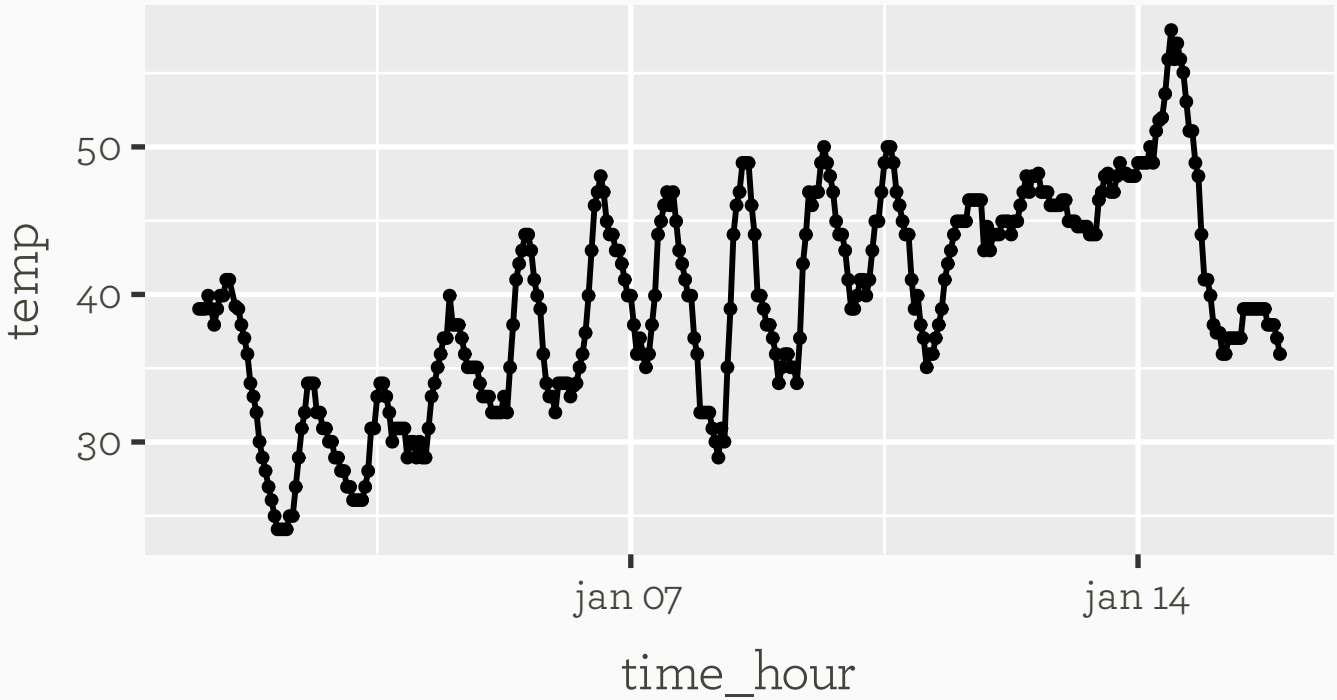

3. Graphiques en lignes

geom_line()

Comme pour geom_point(), nous pouvons modifier l'aspect de la ligne :

```
ggplot(small_weather, aes(x = time_hour, y = temp)) +
  geom_line(size = 0.2, color = "darkorchid", linetype = 2)
```

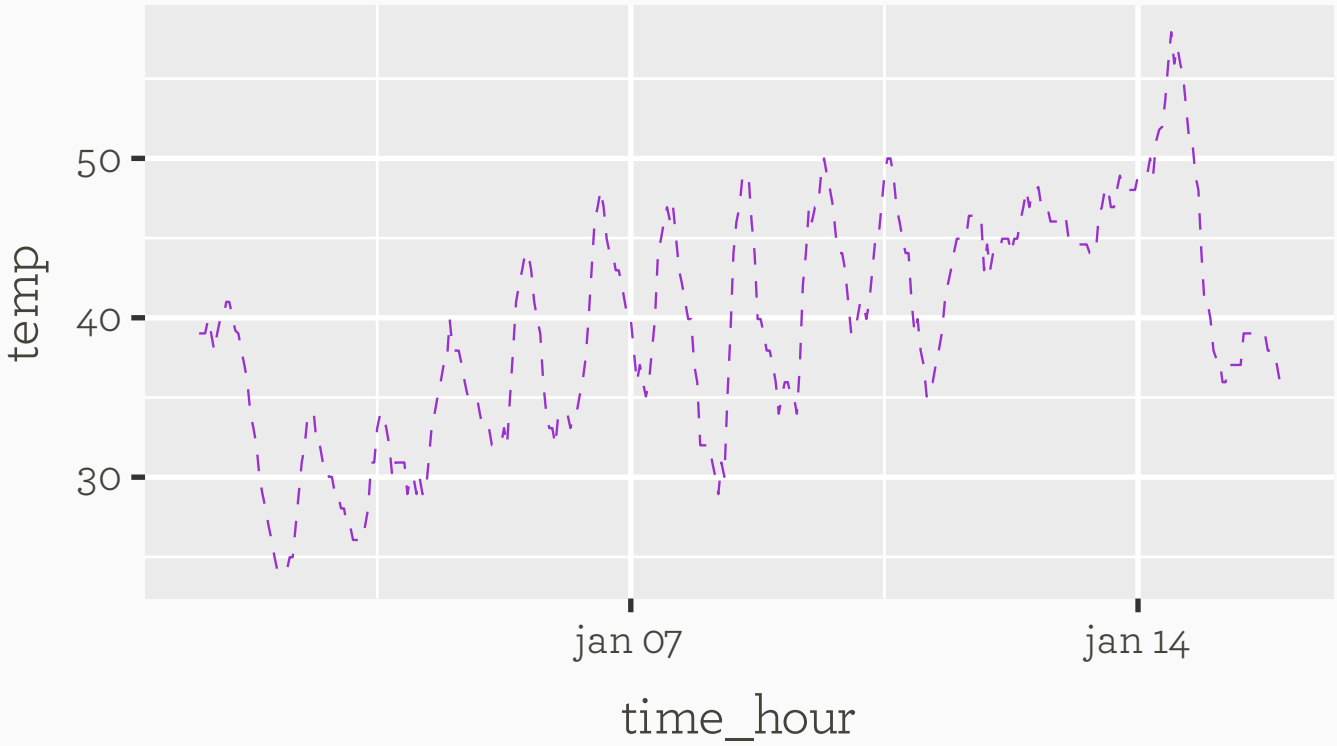

3. Graphiques en lignes

geom_line()

Comme pour geom_point(), nous pouvons associer des variables aux caractéristiques esthétiques des lignes.

Pour l'illustrer, nous allons créer un nouveau jeu de données :

```
small_weather2 <- weather %>%
  filter(month == 1,
         day <= 15)
```

Selon vous, quelles est la différence entre small_weather et small_weather2?

3. Graphiques en lignes

geom_line()

```
ggplot(small_weather2,
       aes(x = time_hour, y = temp, color = origin)) +
  geom_line(alpha = 0.7)
```

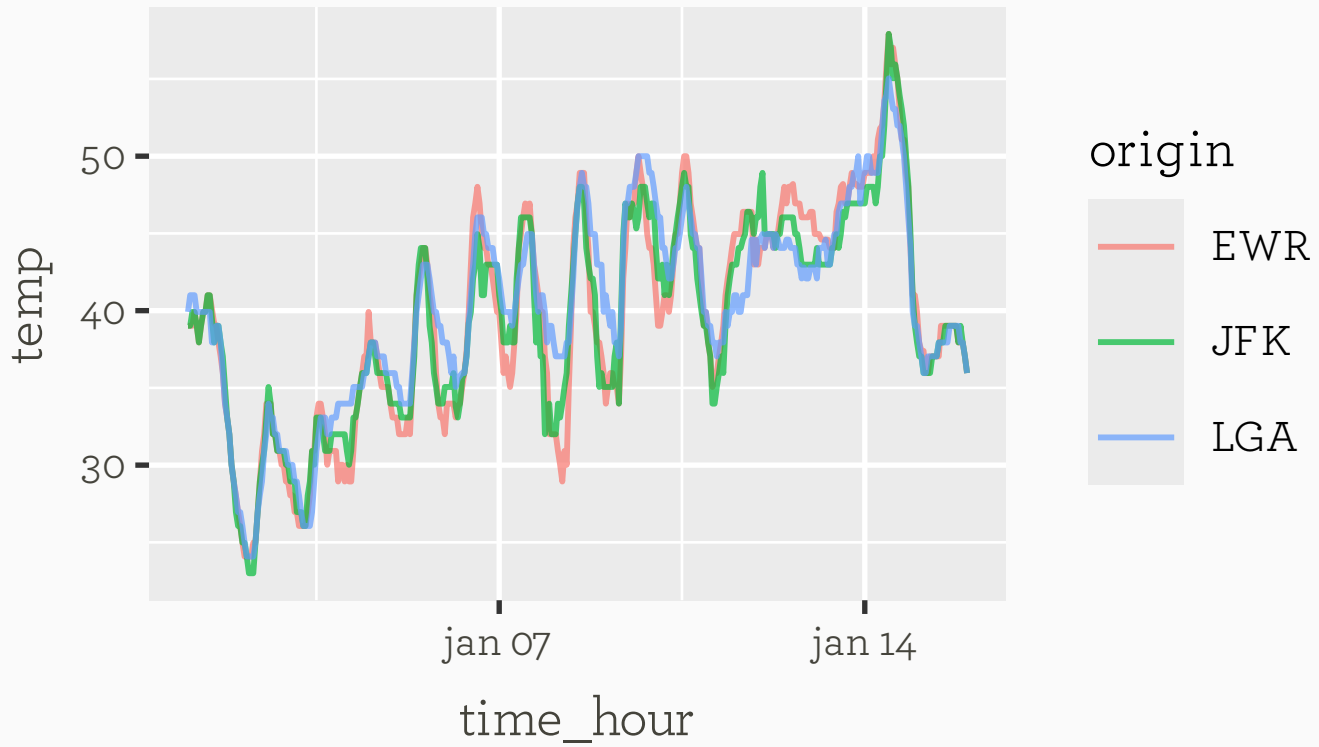

3. Graphiques en lignes

Où placer `aes()` ?

Comparer les 3 graphiques suivants et les commandes associées :

```
ggplot(small_weather,
       aes(x = time_hour, y = temp, color = wind_speed)) +
  geom_line() +
  geom_point(size = 0.5)
```

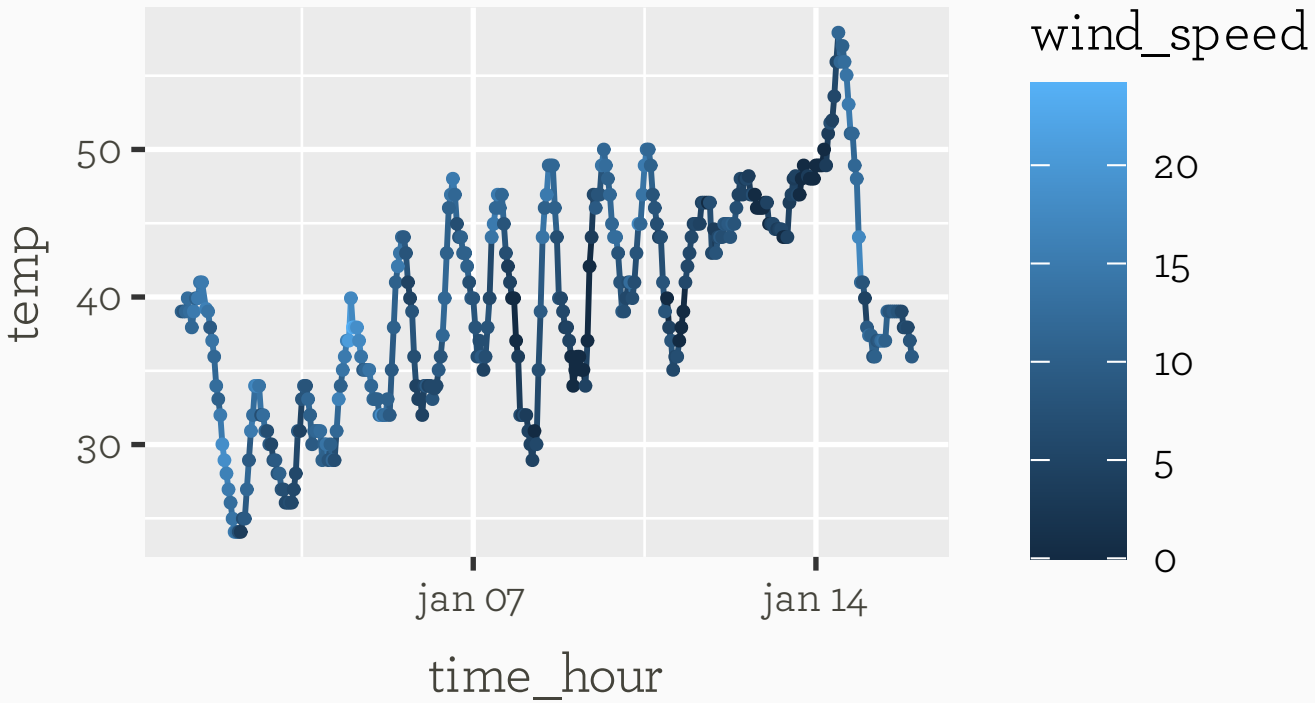

3. Graphiques en lignes

Où placer `aes()` ?

Comparer les 3 graphiques suivants et les commandes associées :

```
ggplot(small_weather,
       aes(x = time_hour, y = temp)) +
  geom_line(aes(color = wind_speed)) +
  geom_point(size = 0.5)
```

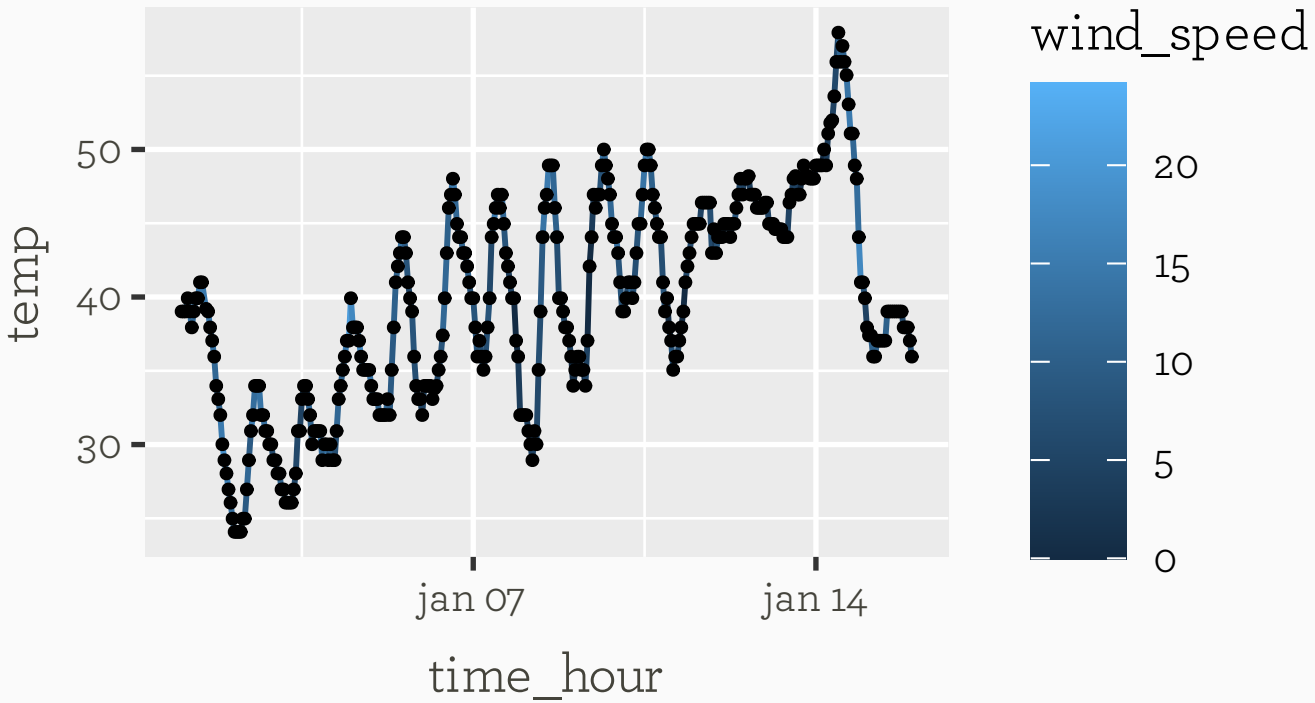

3. Graphiques en lignes

Où placer `aes()` ?

Comparer les 3 graphiques suivants et les commandes associées :

```
ggplot(small_weather,
       aes(x = time_hour, y = temp)) +
  geom_line() +
  geom_point(aes(color = wind_speed), size = 0.5)
```

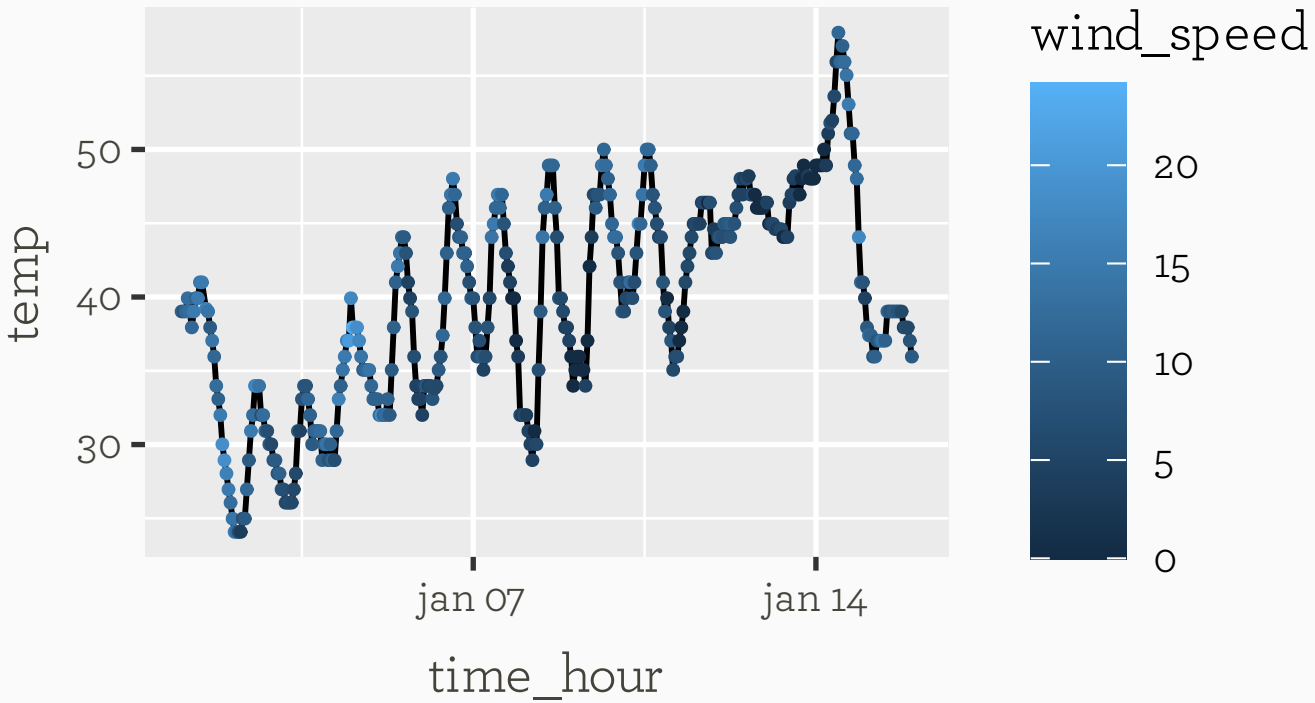

3. Graphiques en lignes

Où placer aes() ? Exercice

Avec le jeu de données dauphin, créez les 4 graphiques ci-dessous [1] :

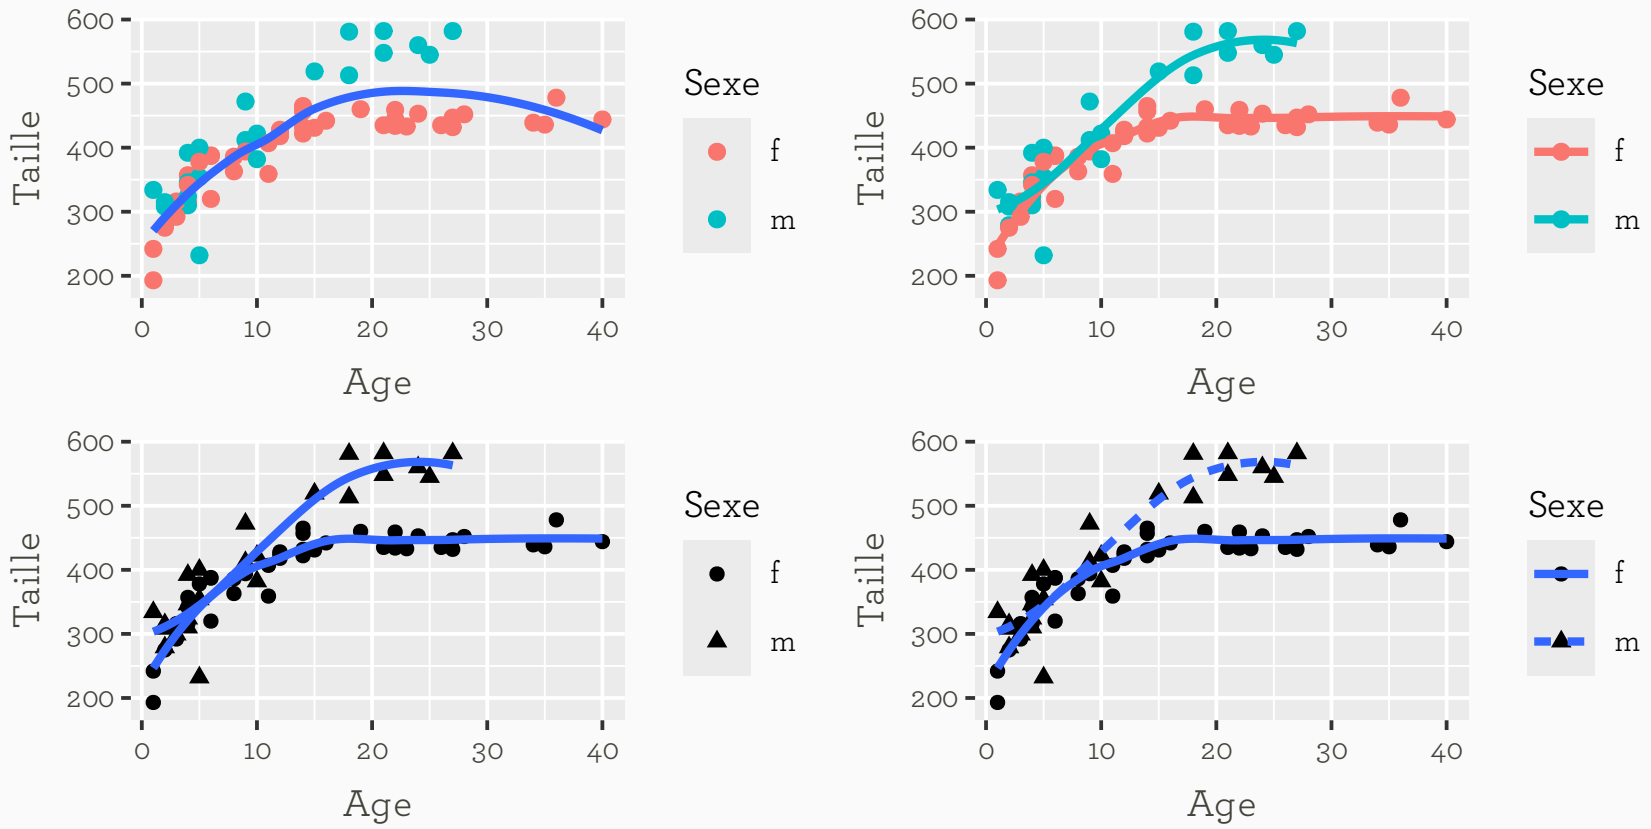

1. Vous aurez besoin de la fonction geom_smooth() et de l'esthétique group.

Visualisation :
4. Les histogrammes

4. Les histogrammes

geom_histogram()

Distribution des températures horaires enregistrées en 2013 dans les 3 aéroports de New York :

```
ggplot(weather, aes(x = temp)) +
  geom_histogram()
```

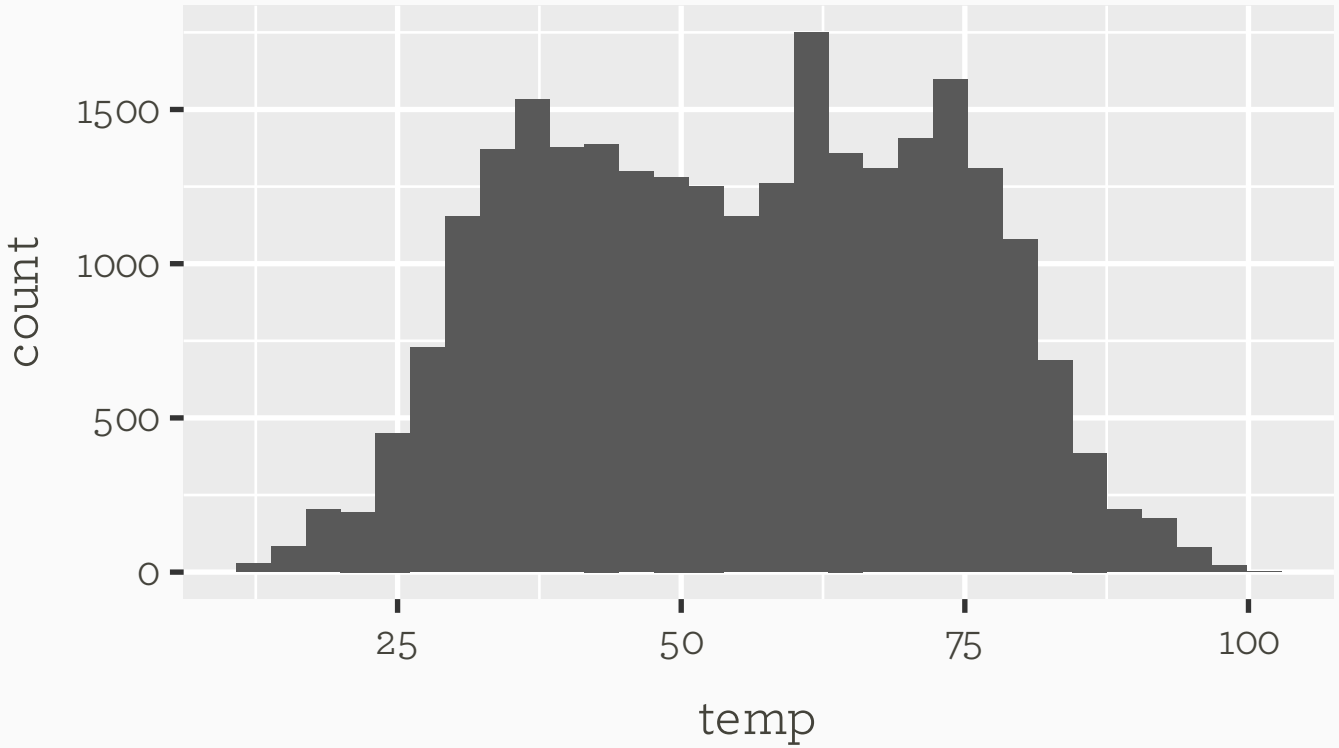

4. Les histogrammes

geom_histogram()

Comme d'habitude, on peut jouer sur un certain nombre de caractéristiques esthétiques :

```
ggplot(weather, aes(x = temp)) +
  geom_histogram(fill = "steelblue", color = "dimgrey")
```

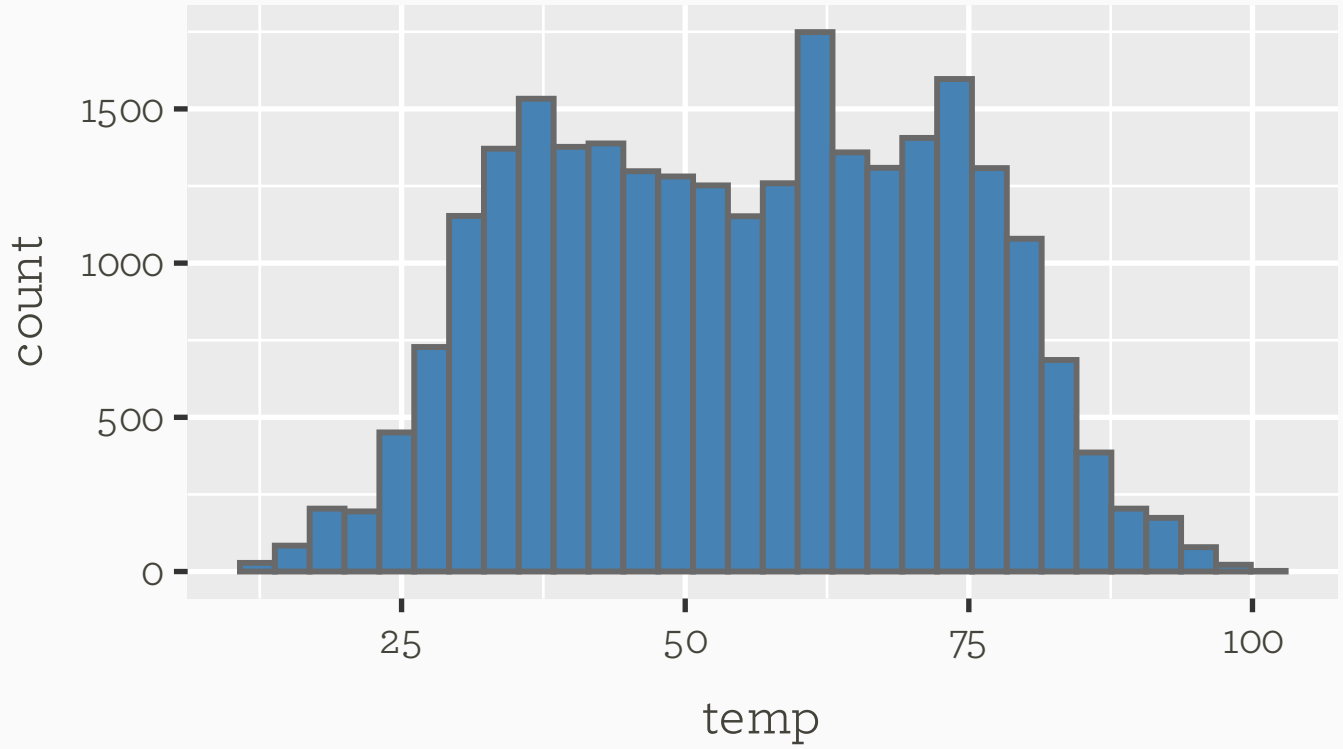

4. Les histogrammes

La taille des classes

On peut spécifier manuellement la largeur des catégories de 3 façons différentes :

1. En ajustant le nombre de classes avec `bins`.
2. En précisant la largeur des classes avec `binwidth`.
3. En fournissant manuellement les limites des classes avec `breaks`.

4. Les histogrammes

La taille des classes

```
ggplot(weather, aes(x = temp)) +
  geom_histogram(bins = 60, color = "white")
```

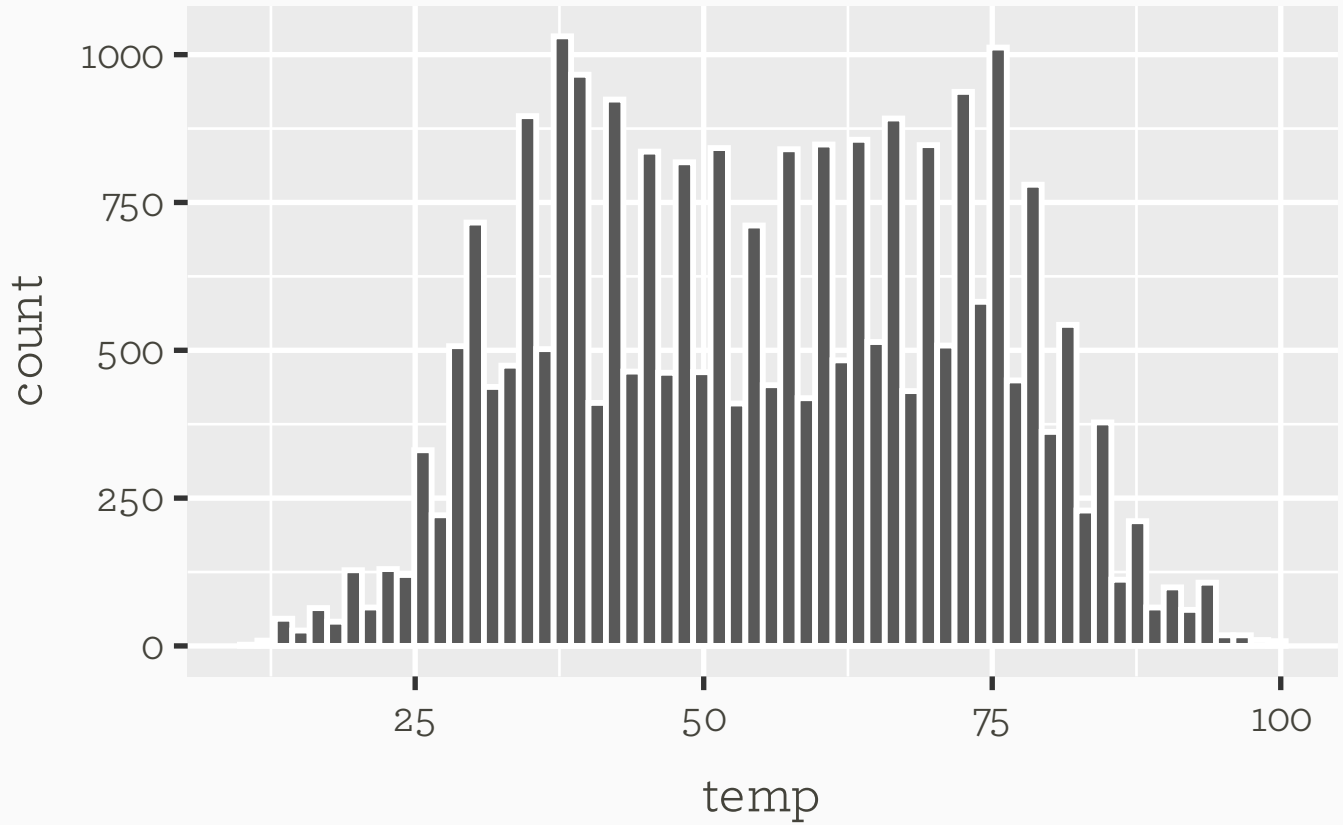

4. Les histogrammes

La taille des classes

```
ggplot(weather, aes(x = temp)) +
  geom_histogram(binwidth = 10, color = "white")
```

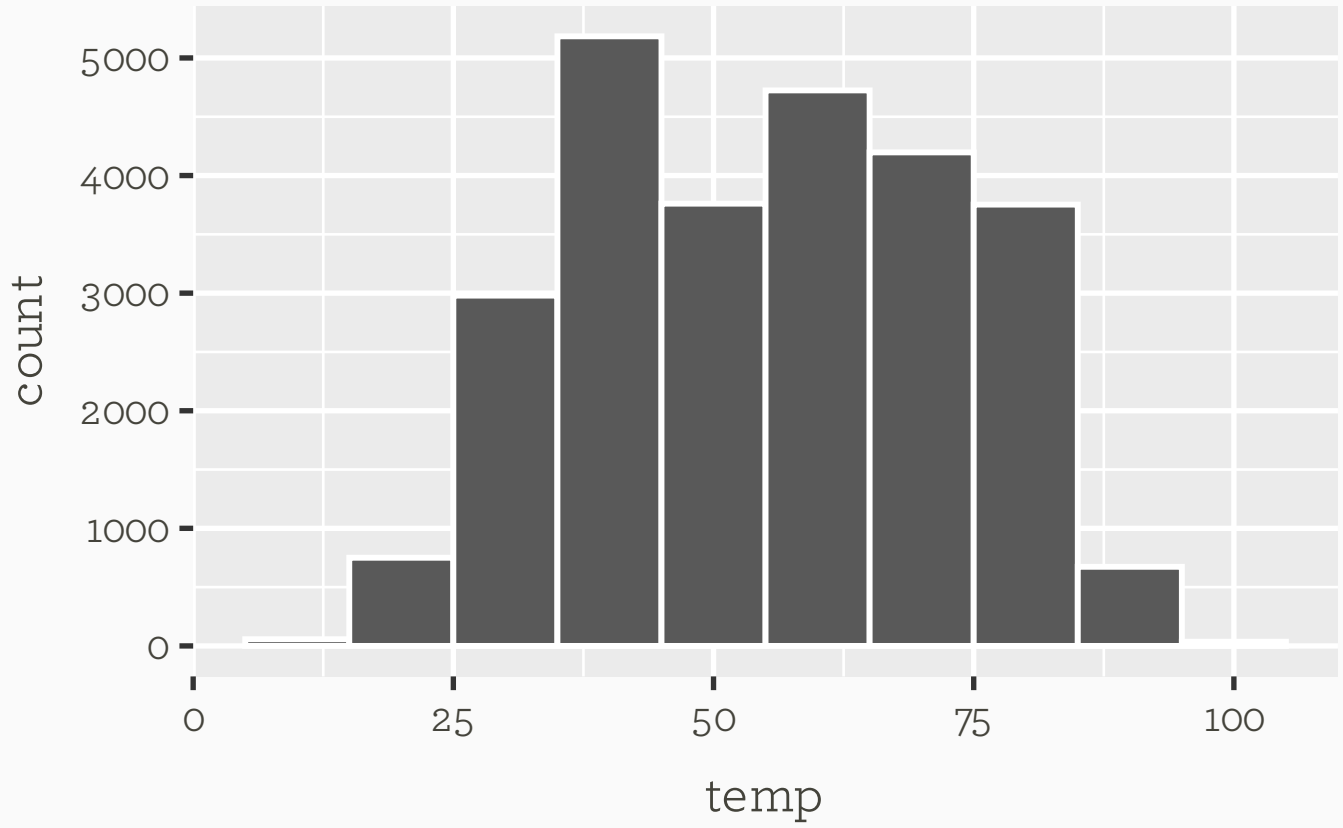

4. Les histogrammes

La taille des classes

```
ggplot(weather, aes(x = temp)) +
  geom_histogram(breaks = c(0, 10, 20, 50, 60, 70, 80, 105),
                 color = "white")
```

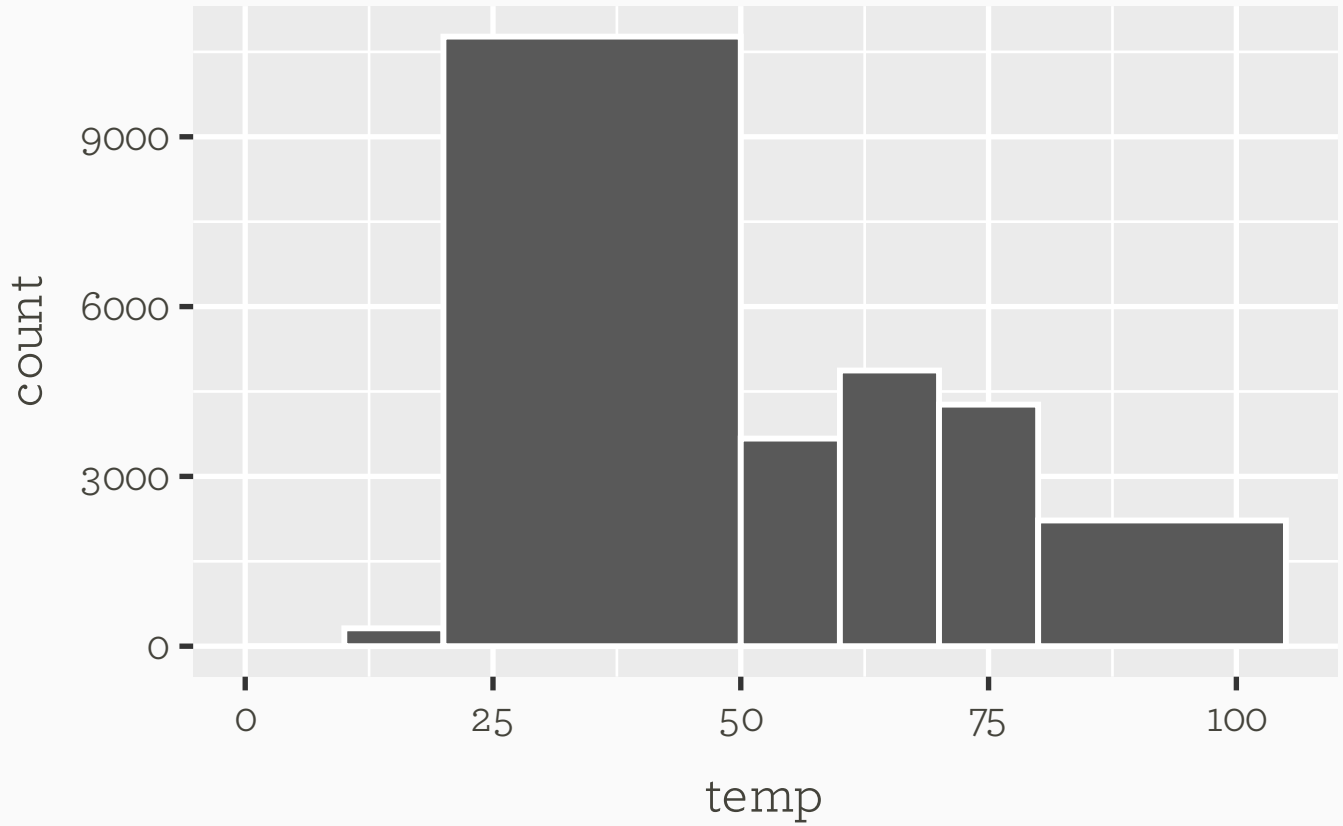

4. Les histogrammes

La taille des classes

```
limits <- seq(from = 10, to = 105, by = 5)
ggplot(weather, aes(x = temp)) +
  geom_histogram(breaks = limits, color = "white")
```

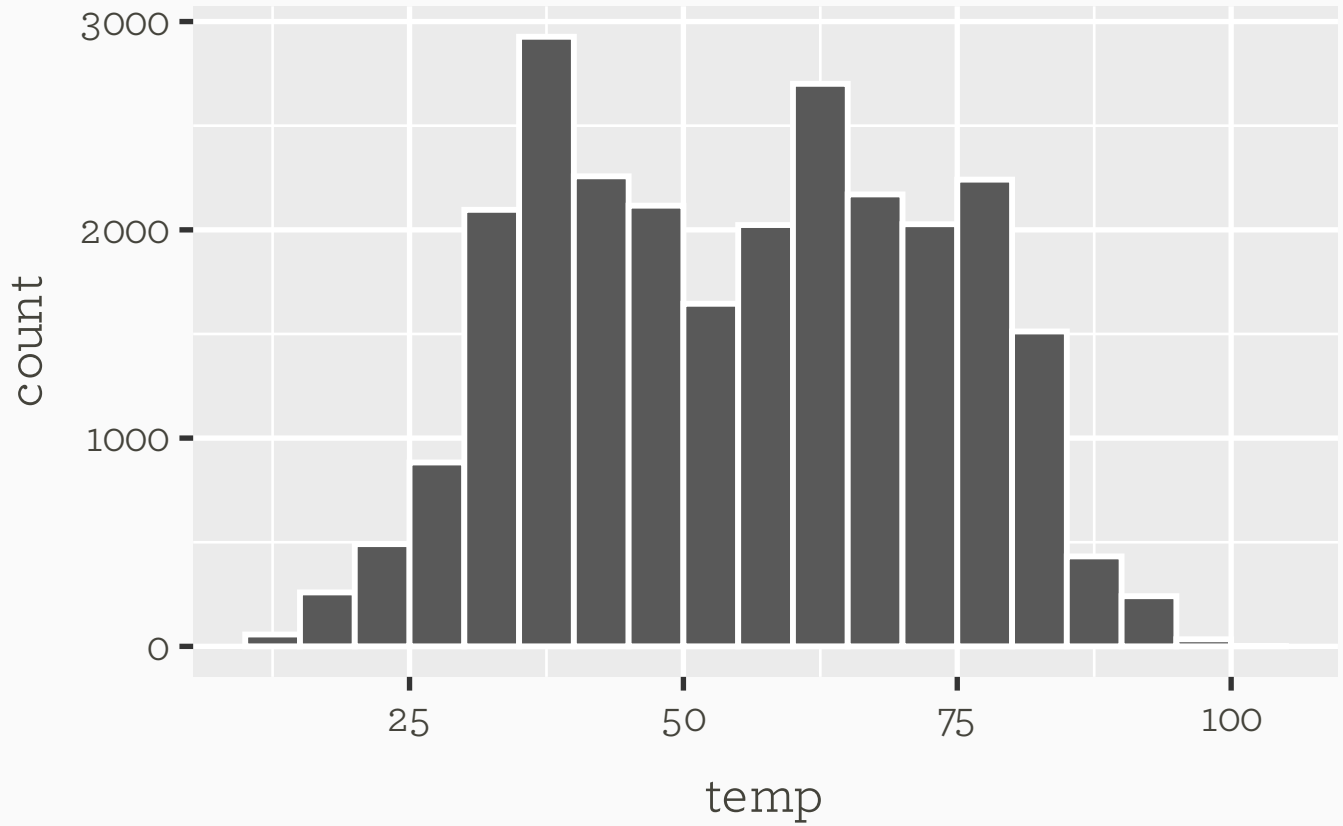

4. Les histogrammes

Variable supplémentaire

Comme pour les autres geom, il est possible d'associer une autre variable à une caractéristique esthétique de l'histogramme :

```
ggplot(weather, aes(x = temp, fill = factor(month))) +
  geom_histogram(bins = 20, color = "grey30")
```

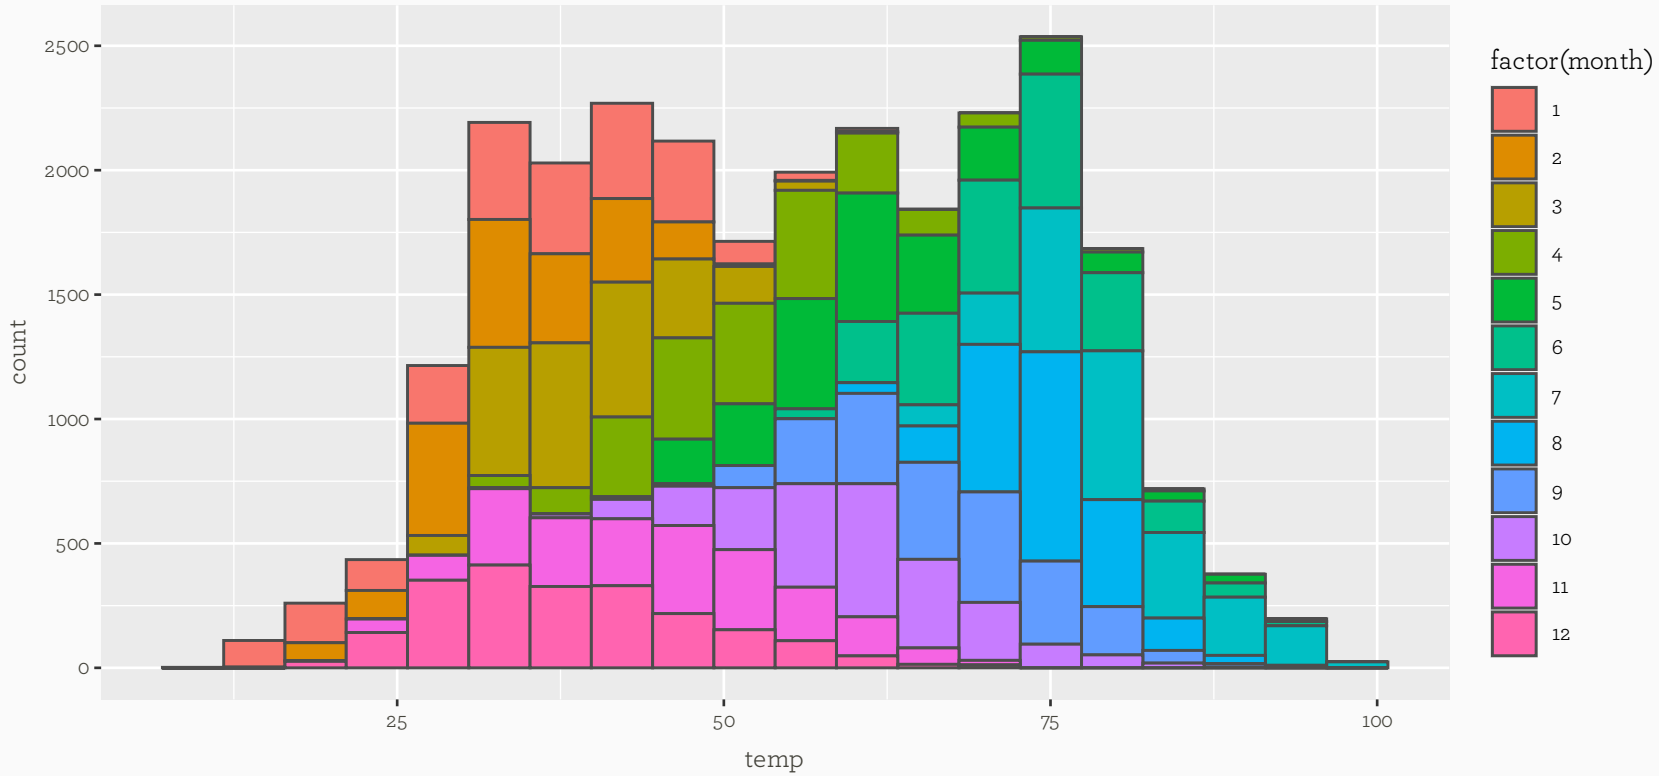

Visualisation :
5. Les facets

5. Les facets

Qu'est-ce que c'est ?

Une autre façon d'ajouter des variables supplémentaires est de séparer le graphiques en plusieurs facettes.

> *Definition*
>
> Un graphique composé de `facet`s est un graphique composé de plusieurs sous-graphiques, chacun d'enre eux présentant une partie des données.

Deux fonctions principales permettent de créer des `facets` :

1. `facet_wrap()` pour séparer en fonction d'une seule variable
2. `facet_grid()` pour séparer en fonction de deux variables

Les variables utilisées pour "facetter" un graphique doivent être catégorielles.

5. Les facets

Exemple

```
ggplot(weather, aes(x = temp, fill = factor(month))) +
  geom_histogram(bins = 20, color = "grey30") +
  facet_wrap(~factor(month), ncol = 4)
```

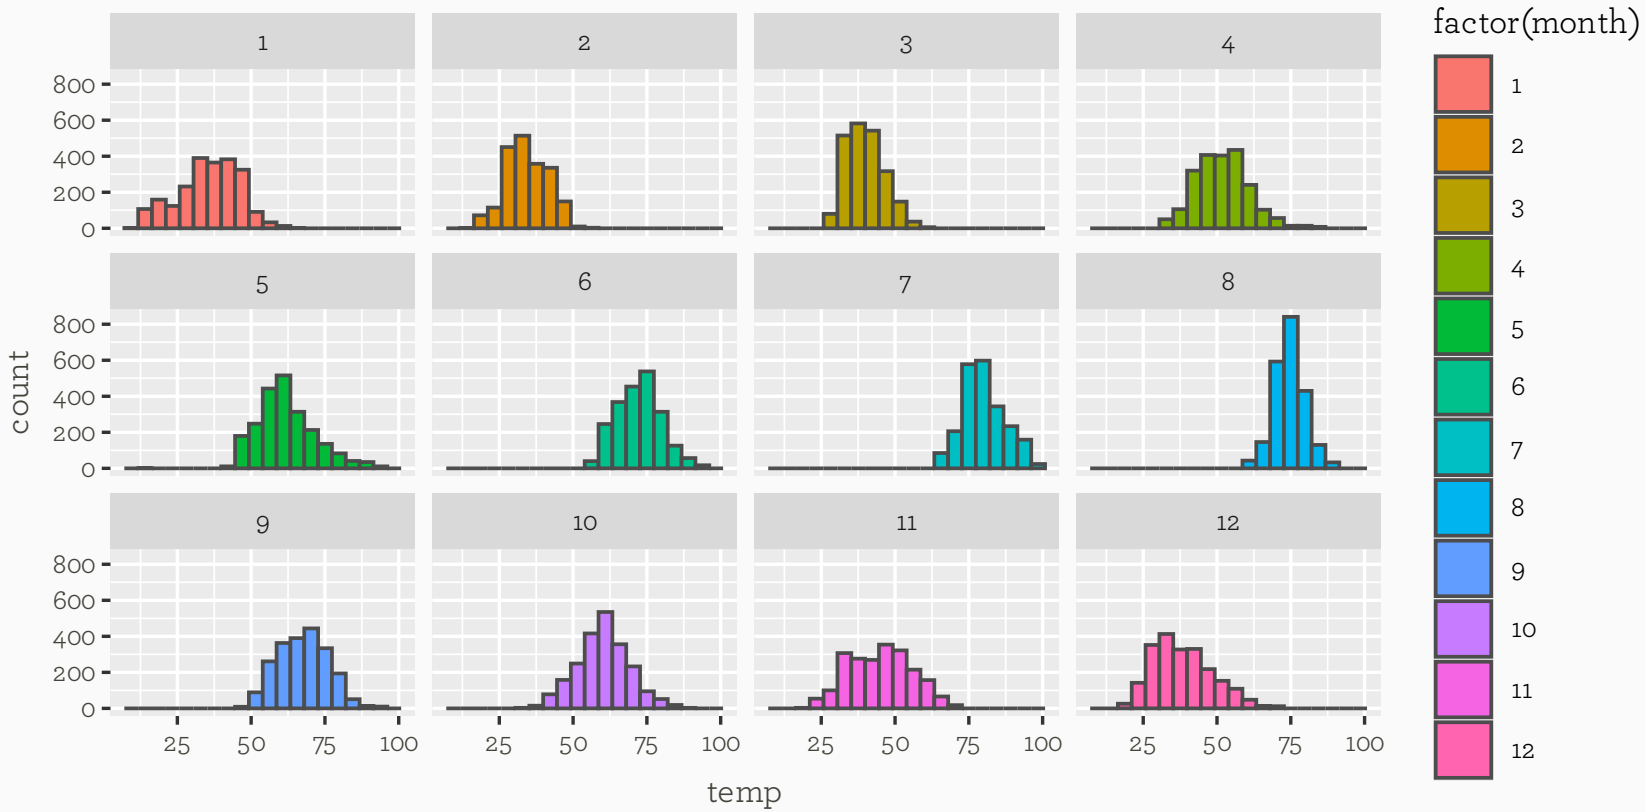

5. Les facets

Exemple

```
ggplot(weather, aes(x = temp, fill = factor(month))) +
  geom_histogram(bins = 20, color = "grey30") +
  facet_grid(factor(month)~origin)
```

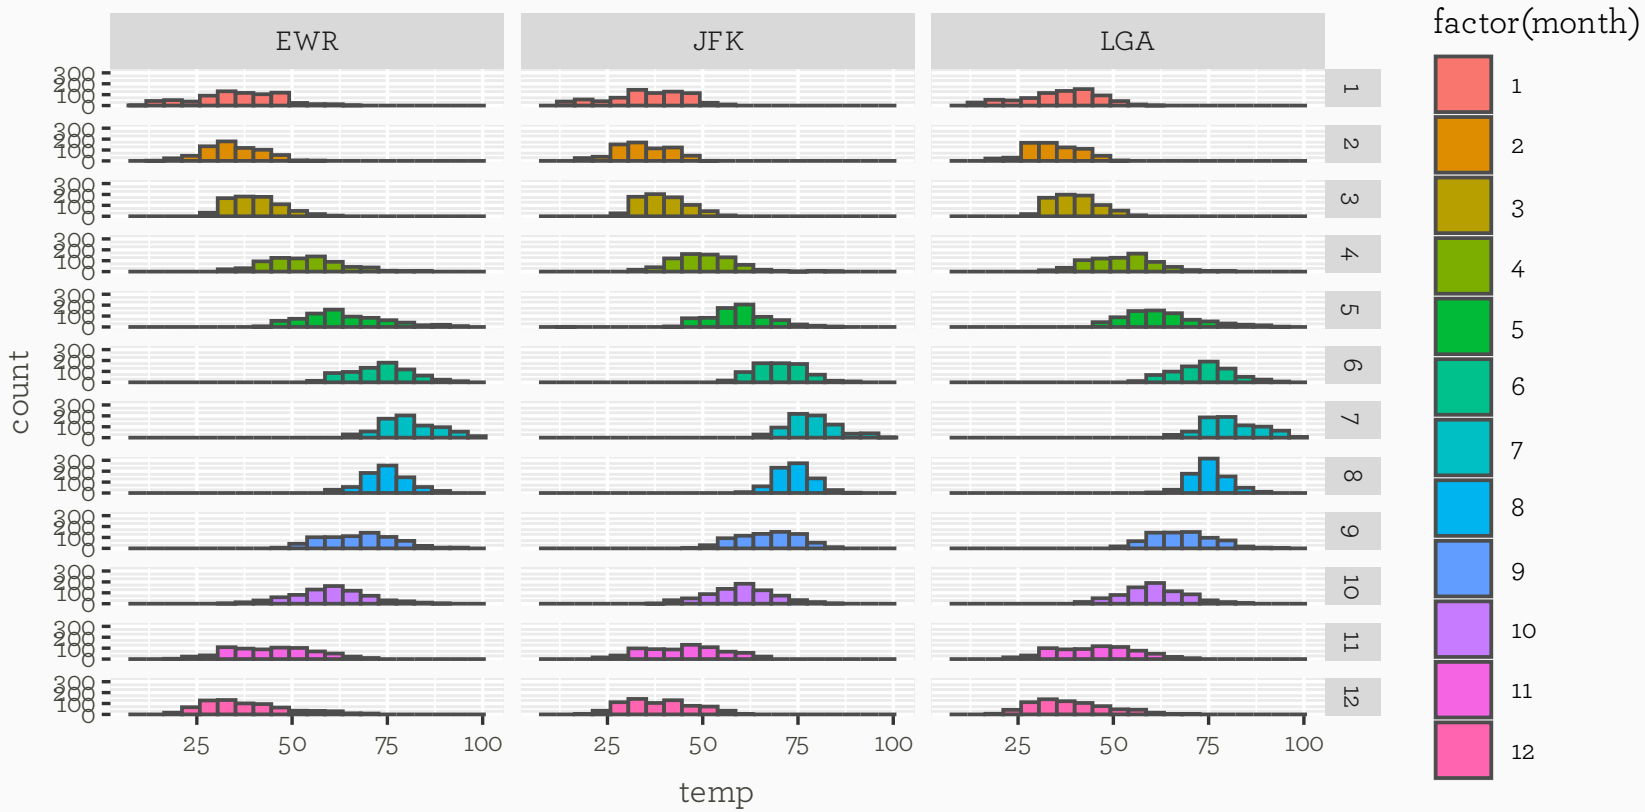

Visualisation :
6. Les boxplots

6. Les boxplots

geom_boxplot()

Toujours avec weather, un boxplot fort peu utile...

```
ggplot(weather, aes(x = month, y = temp)) +
  geom_boxplot()
```

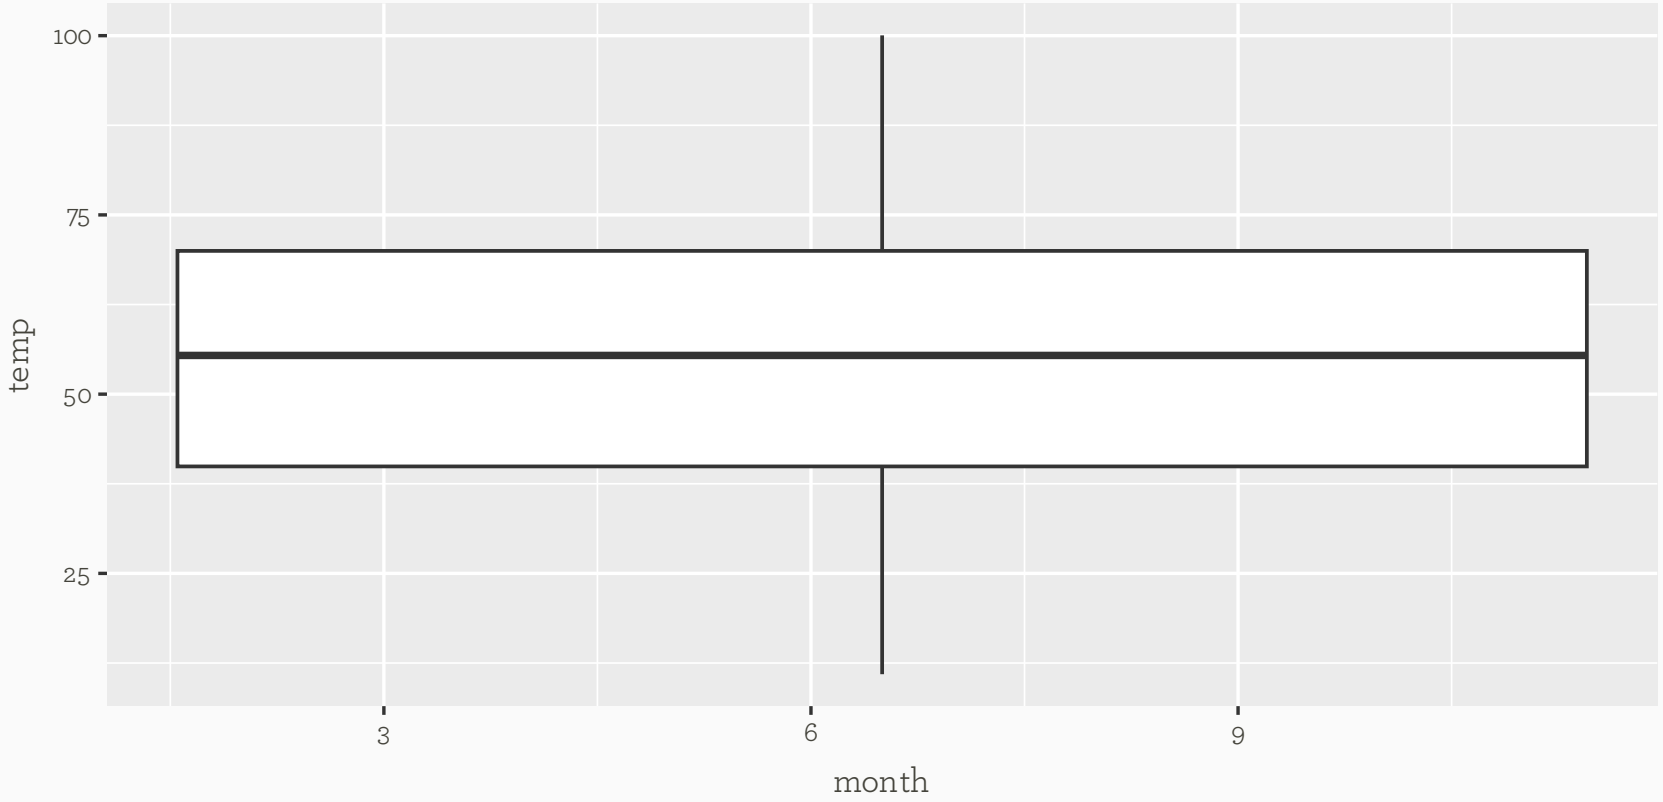

6. Les boxplots

geom_boxplot()

Les boxplots permettent de comparer la distribution d'une variable numériques pour plusieurs modalités d'une variable catégorielle :

```
ggplot(weather, aes(x = factor(month), y = temp)) +
  geom_boxplot()
```

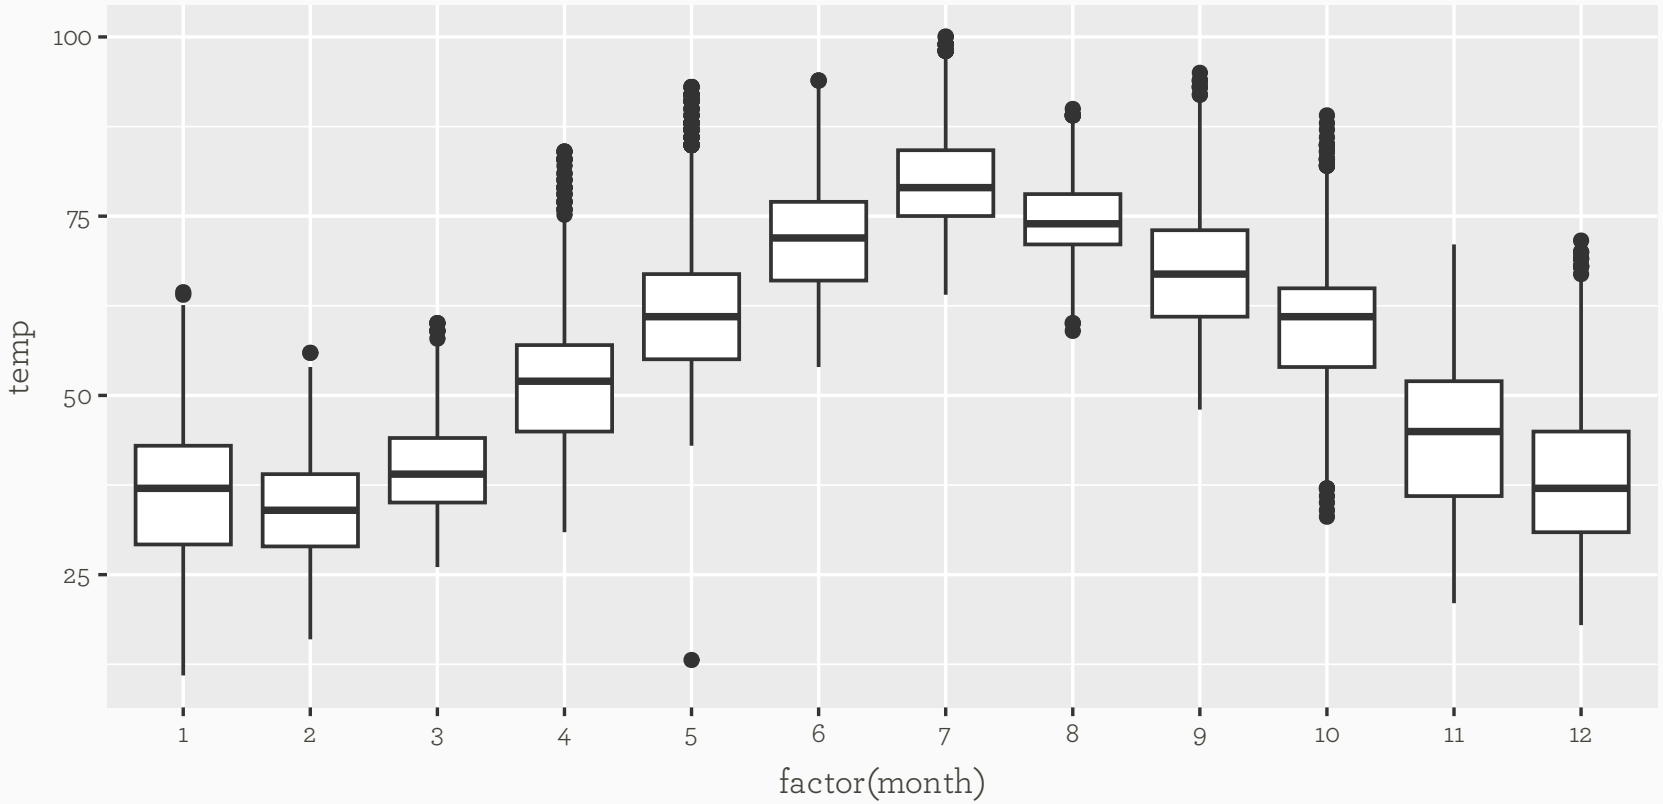

6. Les boxplots

geom_boxplot()

Ajout des intervalles de confiance à 95% des médianes :

```
ggplot(weather, aes(x = factor(month), y = temp)) +
  geom_boxplot(fill = "darkorchid", notch = TRUE)
```

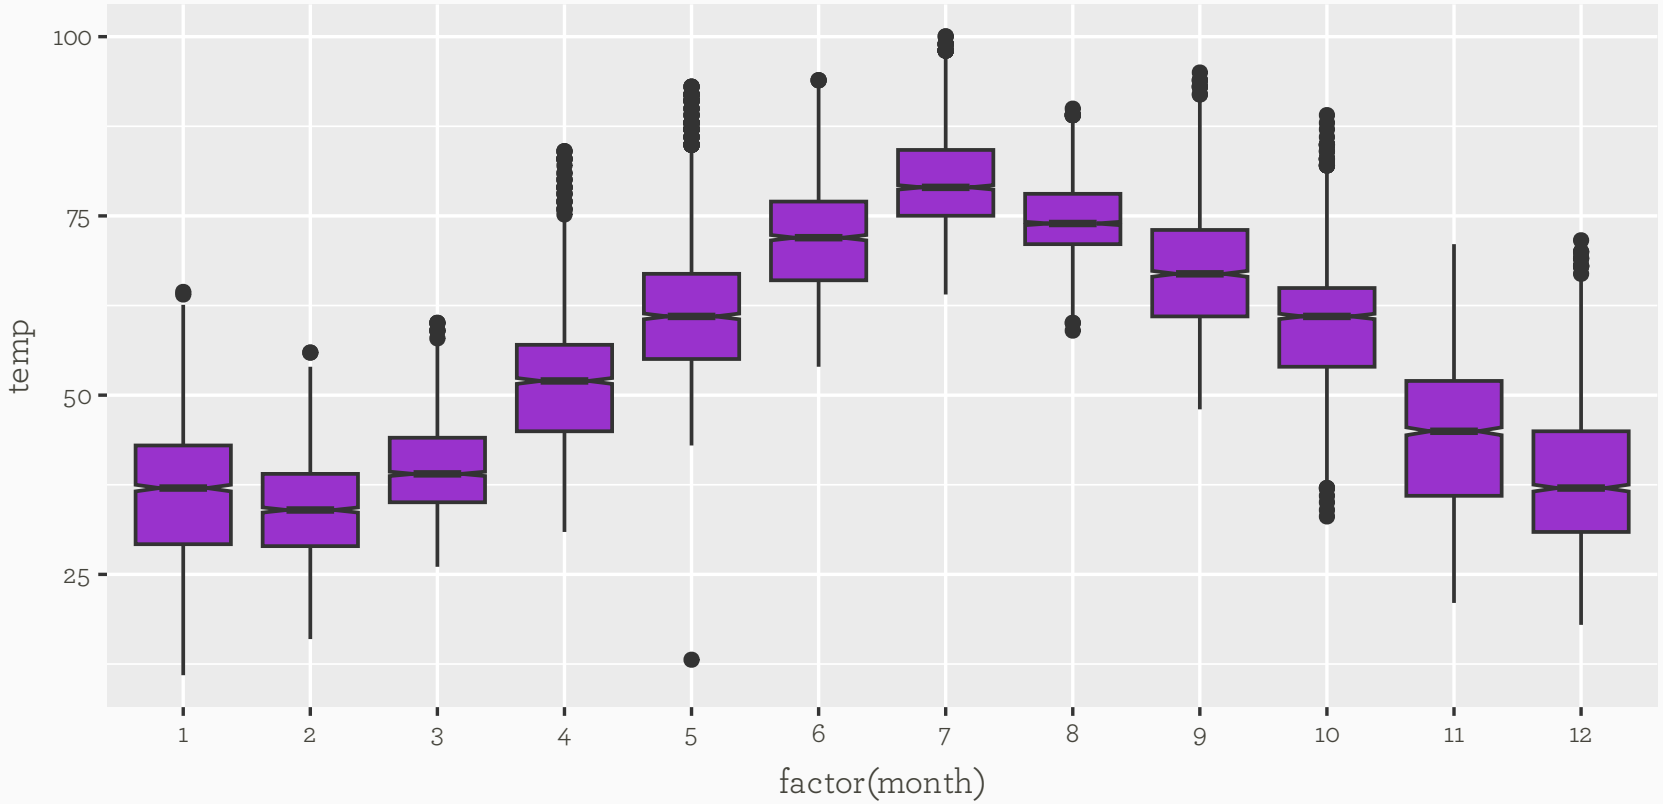

6. Les boxplots

Exercice

Avec le jeu de données `flights`, produisez le graphique suivant :

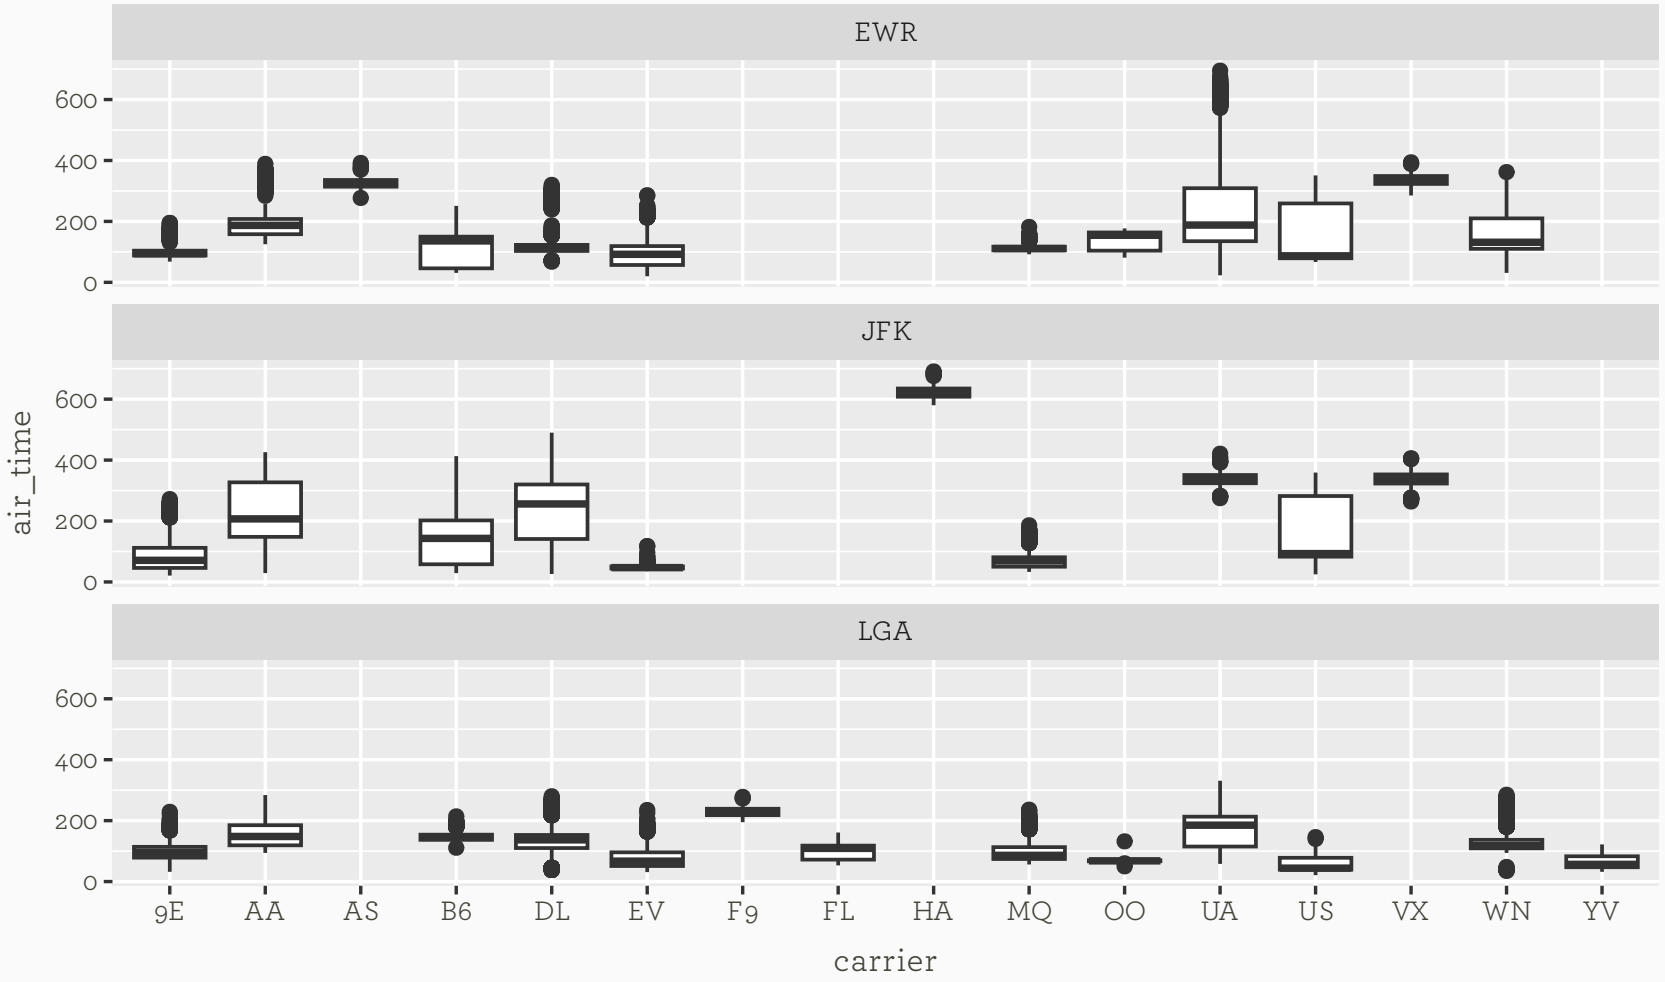

Que nous apprend-il ?

6. Les boxplots

Une autre façon d'examiner des distributions

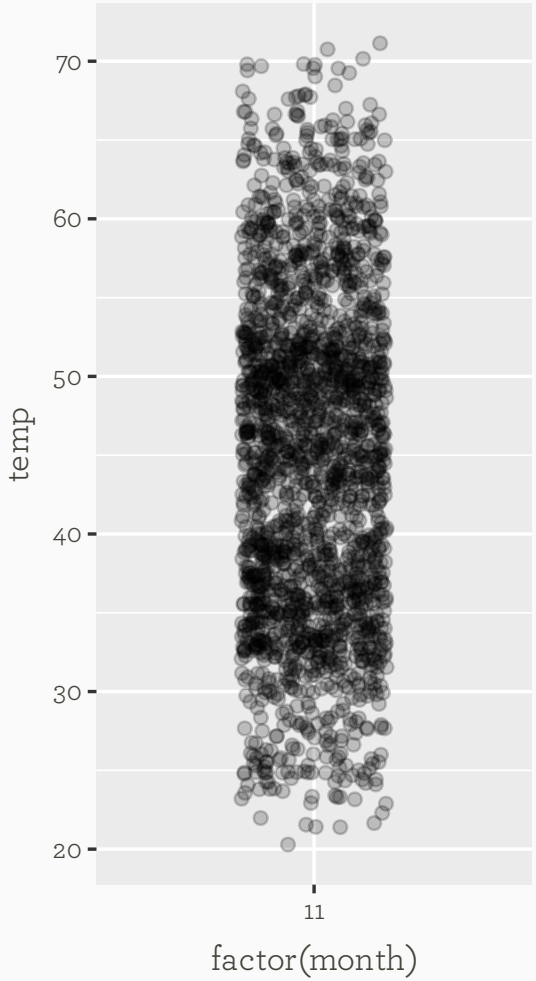

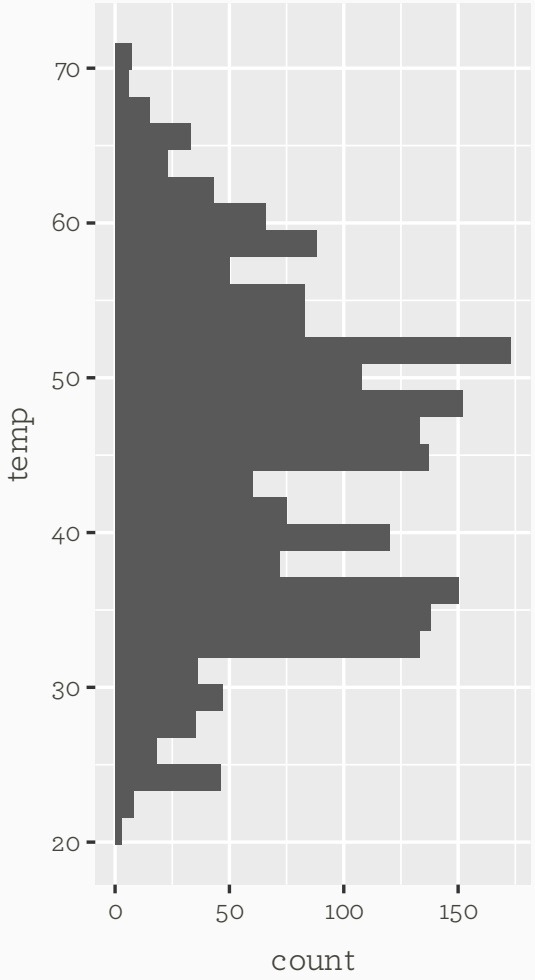

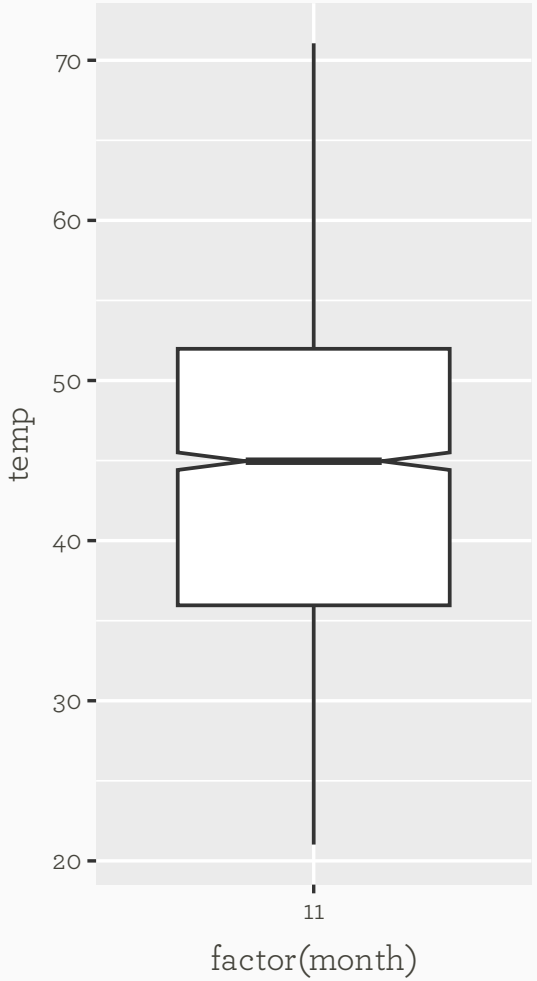

Visualisation : 7. Les diagrammes bâtons

7. Les diagrammes bâtons

geom_bar()

Revenons au jeu de données `flights`. Combien de vols ont été affrétés en 2013 par chaque compagnie aérienne ?

```
ggplot(flights, aes(x = carrier)) +
  geom_bar()
```

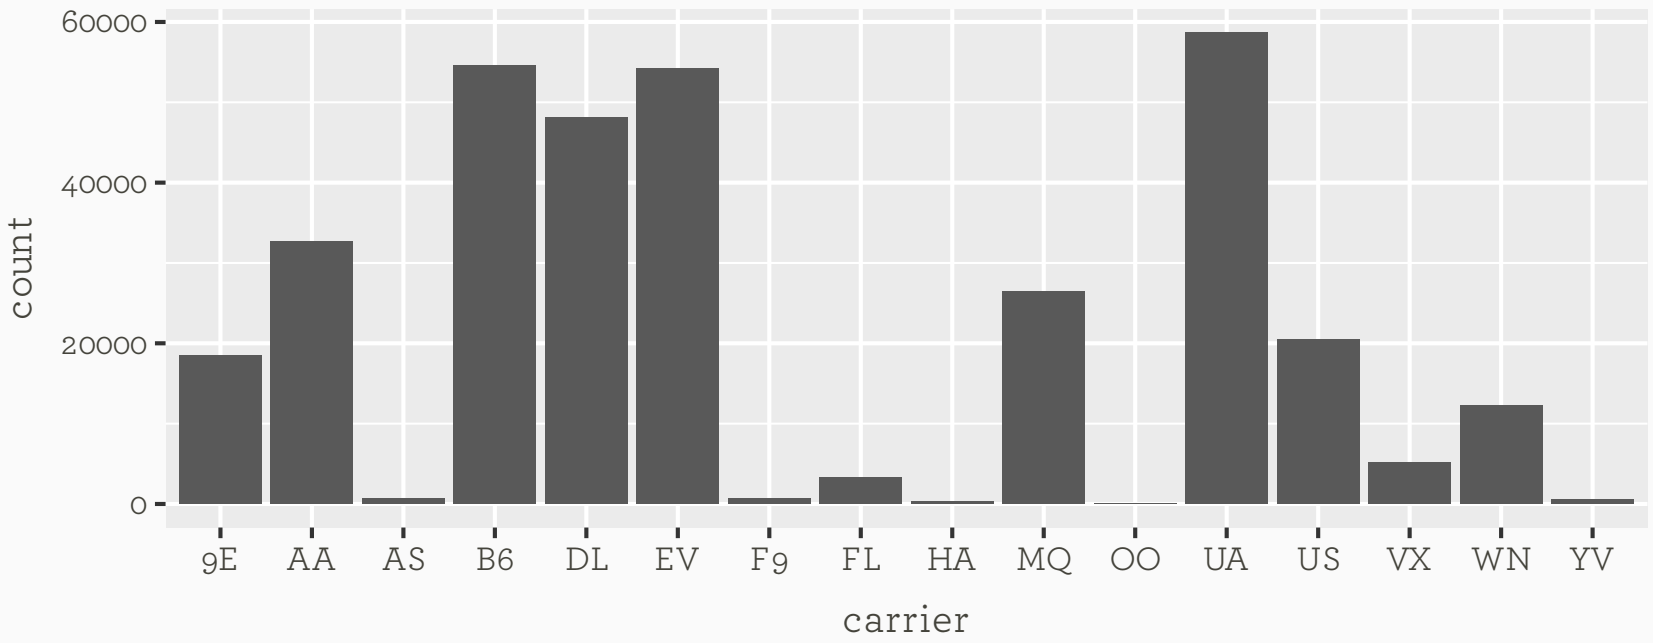

7. Les diagrammes bâtons

`geom_bar()`

Affichez le contenu de la variable `carrier`.

- Selon vous, comment le graphique précédent a-t'il été produit ?
- Quelle variable a été associée (“mappée”) à l'axe des ordonnées ?

Si `carrier` est bien une variable de `flights`, `count` n'en est pas une.
D'où vient cette variable ?

7. Les diagrammes bâtons

geom_bar()

Les diagrammes bâtons sont souvent plus parlants quand les catégories sont triées :

```
ggplot(flights, aes(x = fct_infreq(carrier))) +
  geom_bar()
```

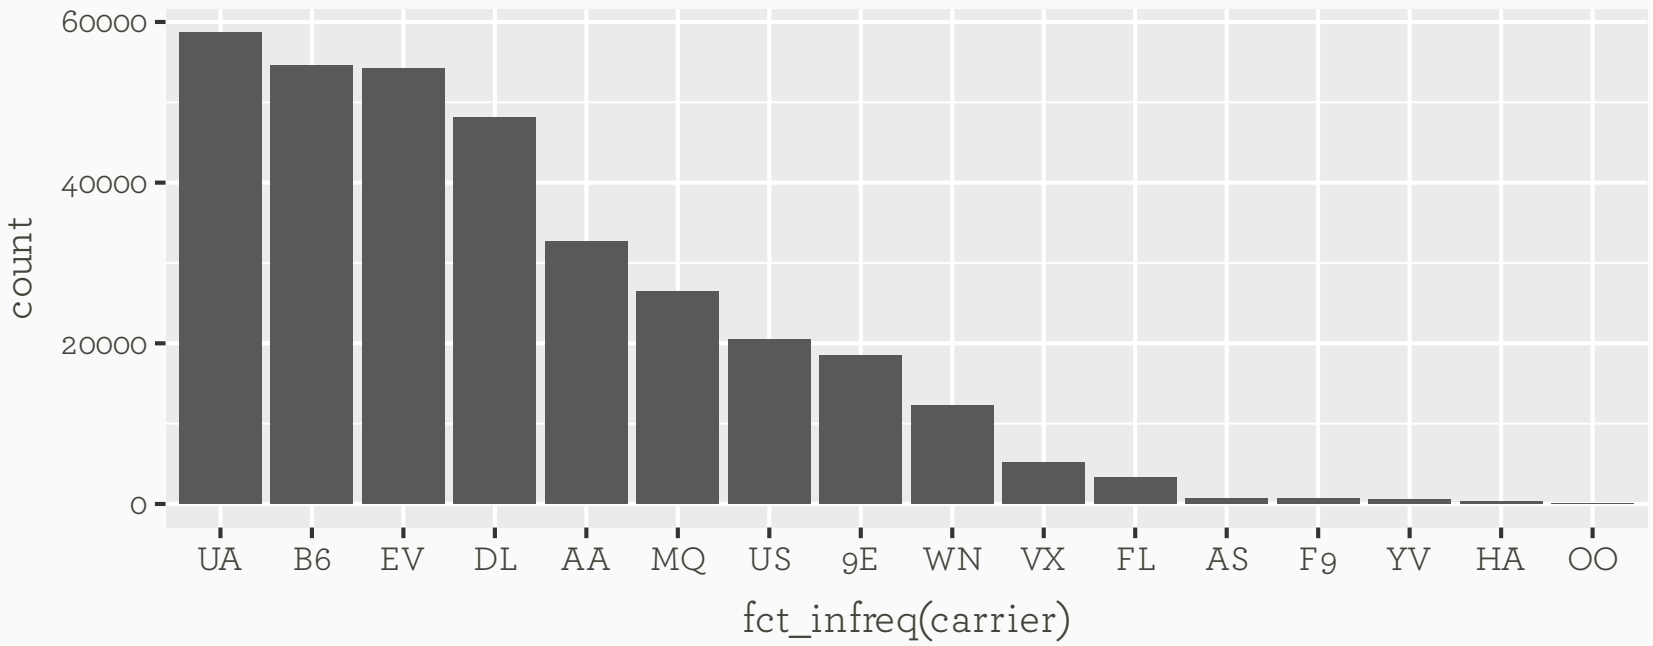

7. Les diagrammes bâtons

geom_col()

Parfois, les données brutes ne sont pas disponibles, et nous disposons seulement de données déjà comptées :

```
# On prend flights, puis...
carrier_table <- flights %>%
  # On groupe les données par compagnie, puis...
  group_by(carrier) %>%
  # On calcule le nb de vols par Cie, puis ...
  summarize(nombre = n()) %>%
  # On trie le tableau par nb de vols décroissant
  arrange(desc(nombre))
```

7. Les diagrammes bâtons

geom_col()

Parfois, les données brutes ne sont pas disponibles, et nous disposons seulement de données déjà comptées :

```
# Enfin, on affiche la nouvelle table
carrier_table

# A tibble: 16 x 2
   carrier nombre
   <chr>    <int>
 1 UA       58665
 2 B6       54635
 3 EV       54173
 4 DL       48110
 5 AA       32729
 6 MQ       26397
 7 US       20536
 8 9E       18460
 9 WN       12275
10 VX        5162
11 FL        3260
12 AS         714
13 F9         685
14 YV         601
15 HA         342
16 OO          32
```

7. Les diagrammes bâtons

geom_col()

Que faire si on ne dispose que de ces données “résumées”?

```
ggplot(carrier_table, aes(x = carrier, y = nombre)) +
  geom_col()
```

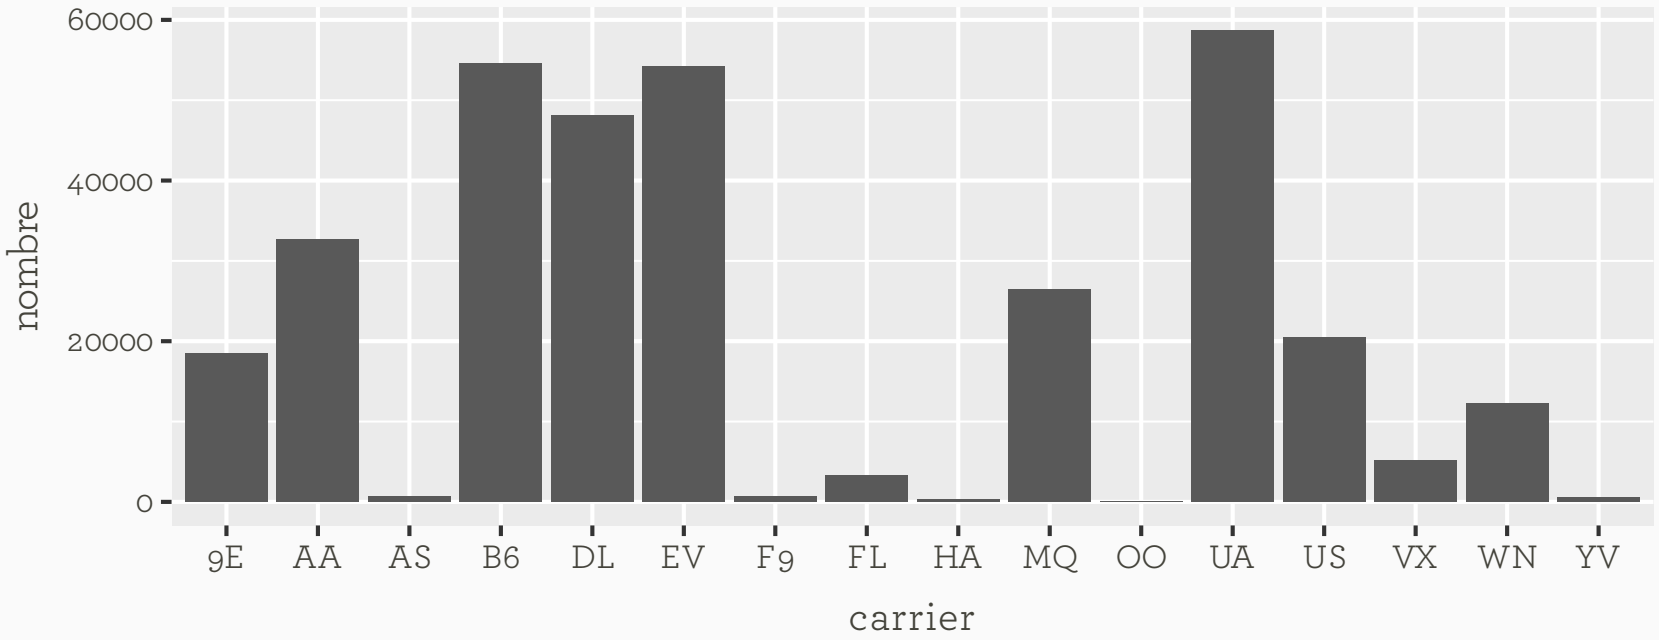

Pourquoi les barres ne sont-elles pas ordonnées?

7. Les diagrammes bâtons

geom_col()

La table carrier_table est triée, mais pas les niveaux du facteur carrier :

```
factor(carrier_table$carrier)
```

```
 [1] UA B6 EV DL AA MQ US 9E WN VX FL AS F9 YV HA OO
Levels: 9E AA AS B6 DL EV F9 FL HA MQ OO UA US VX WN YV
```

Les modalités sont toujours triées par ordre alphabétique.

Pour les modifier, il faut utiliser la fonction fct_reorder().

7. Les diagrammes bâtons

geom_col()

```
ggplot(carrier_table,
       aes(x = fct_reorder(carrier, nombre, .desc = TRUE),
           y = nombre)) +
  geom_col()
```

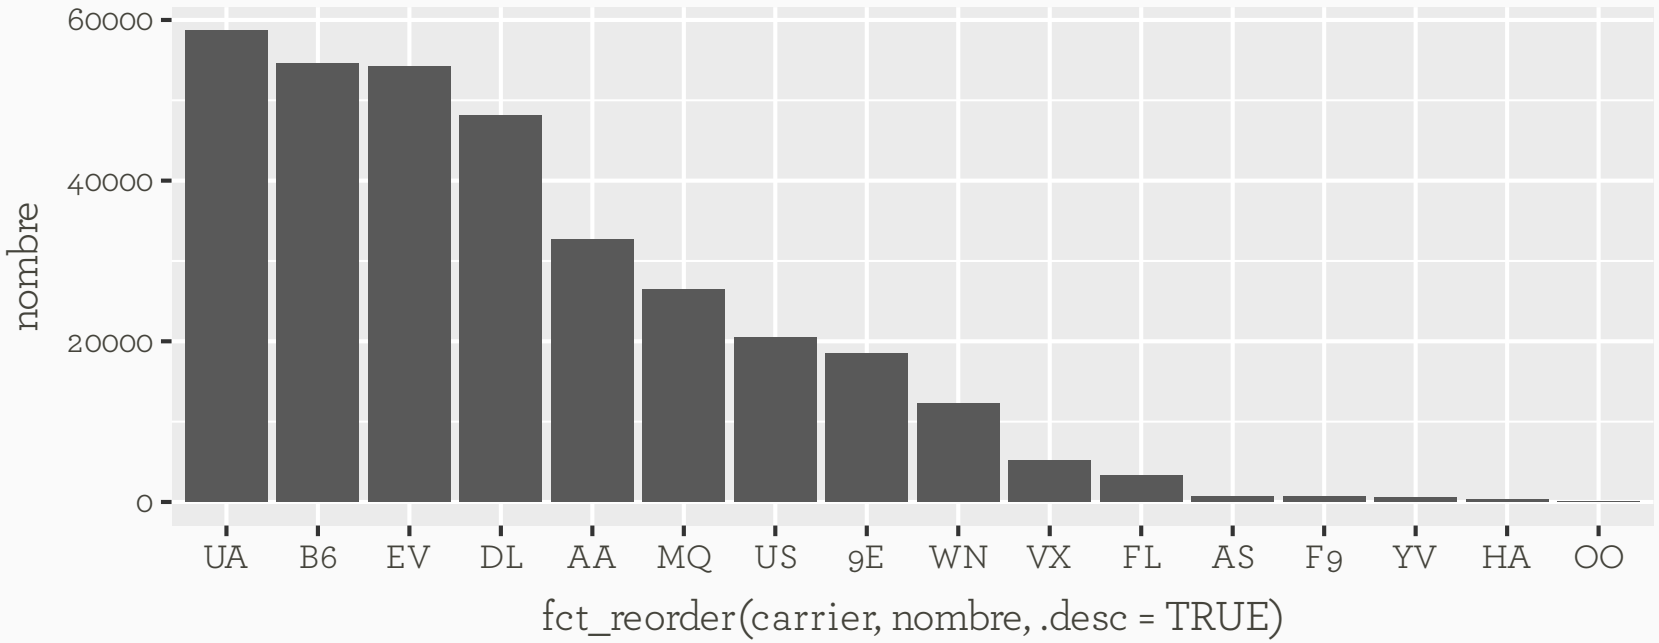

7. Les diagrammes bâtons

Comparer 2 variables catégorielles

```
ggplot(flights, aes(x = fct_infreq(carrier), fill = origin)) +
  geom_bar(color = "black")
```

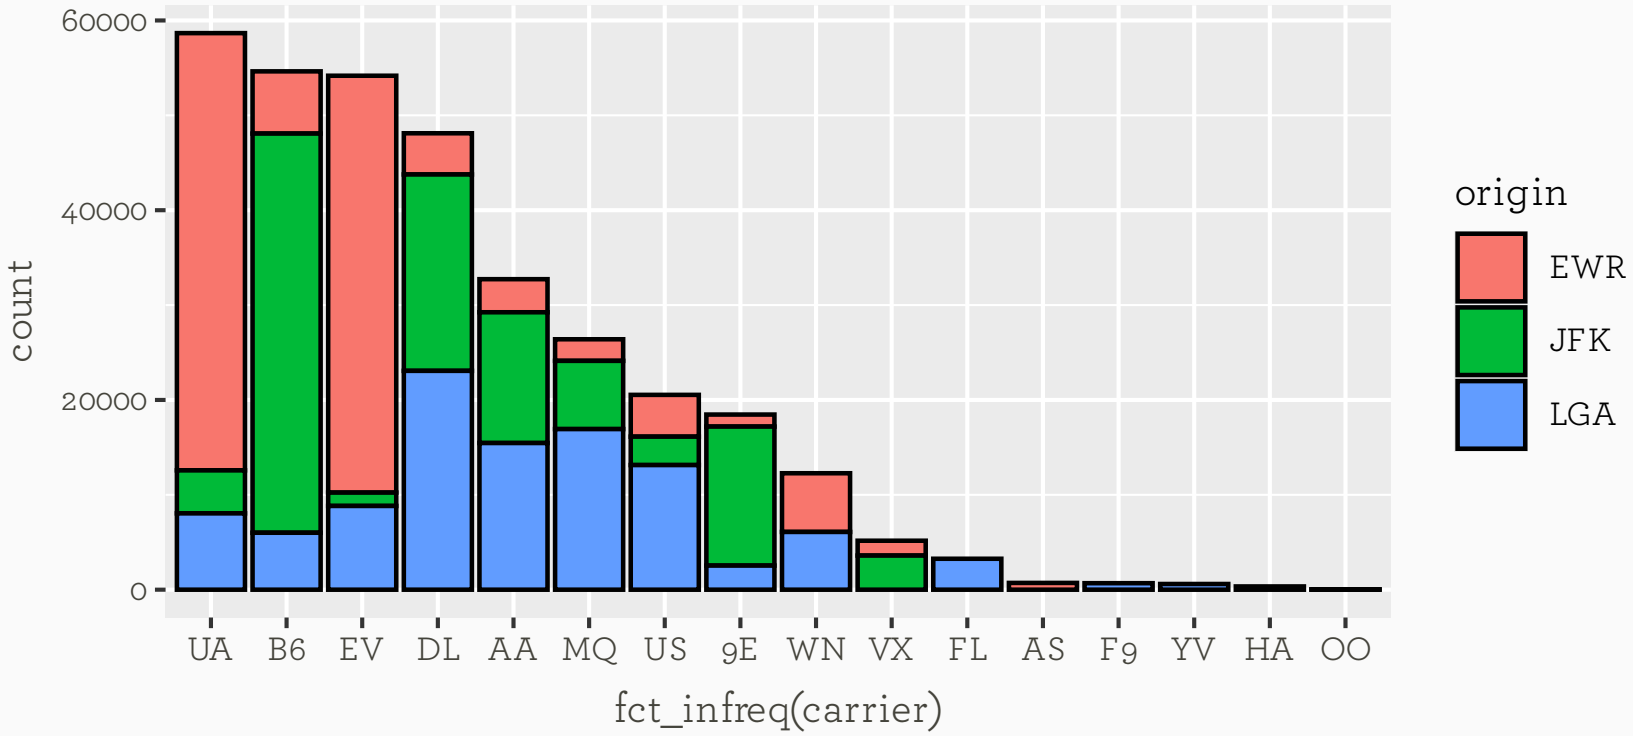

Il est rare que les barres empilées soient le choix le plus judicieux.

7. Les diagrammes bâtons

Comparer 2 variables catégorielles

Pour augmenter la lisibilité, on peut modifier la position des barres :

```
ggplot(flights, aes(x = fct_infreq(carrier), fill = origin)) +
  geom_bar(color = "black", position = "dodge")
```

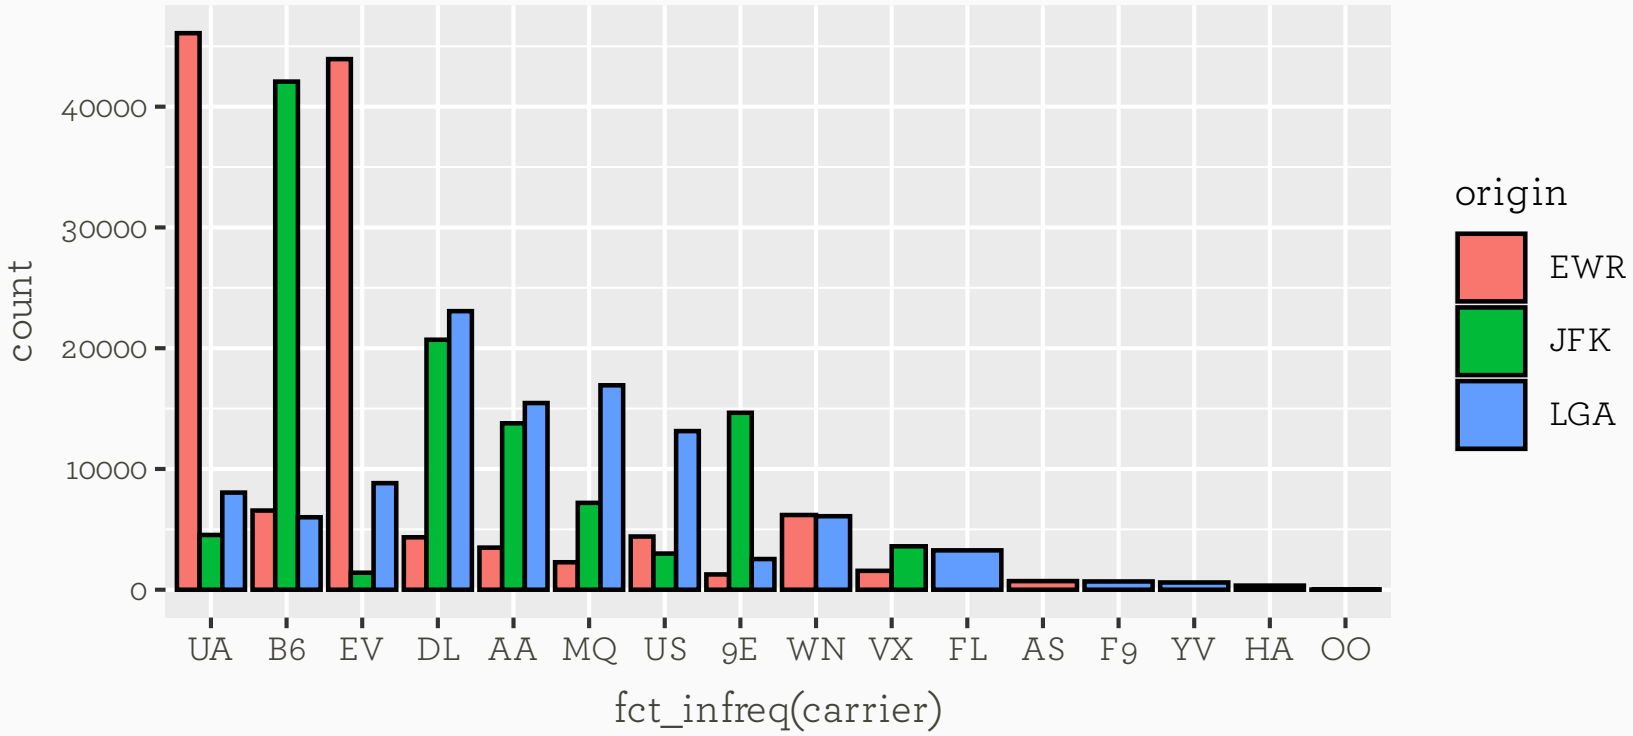

7. Les diagrammes bâtons

Comparer 2 variables catégorielles

Le plus simple reste souvent l'utilisation des `facets` :

```
ggplot(flights, aes(x = fct_infreq(carrier), fill = origin)) +
  geom_bar(color = "black") +
  facet_wrap(~origin, ncol = 1)
```

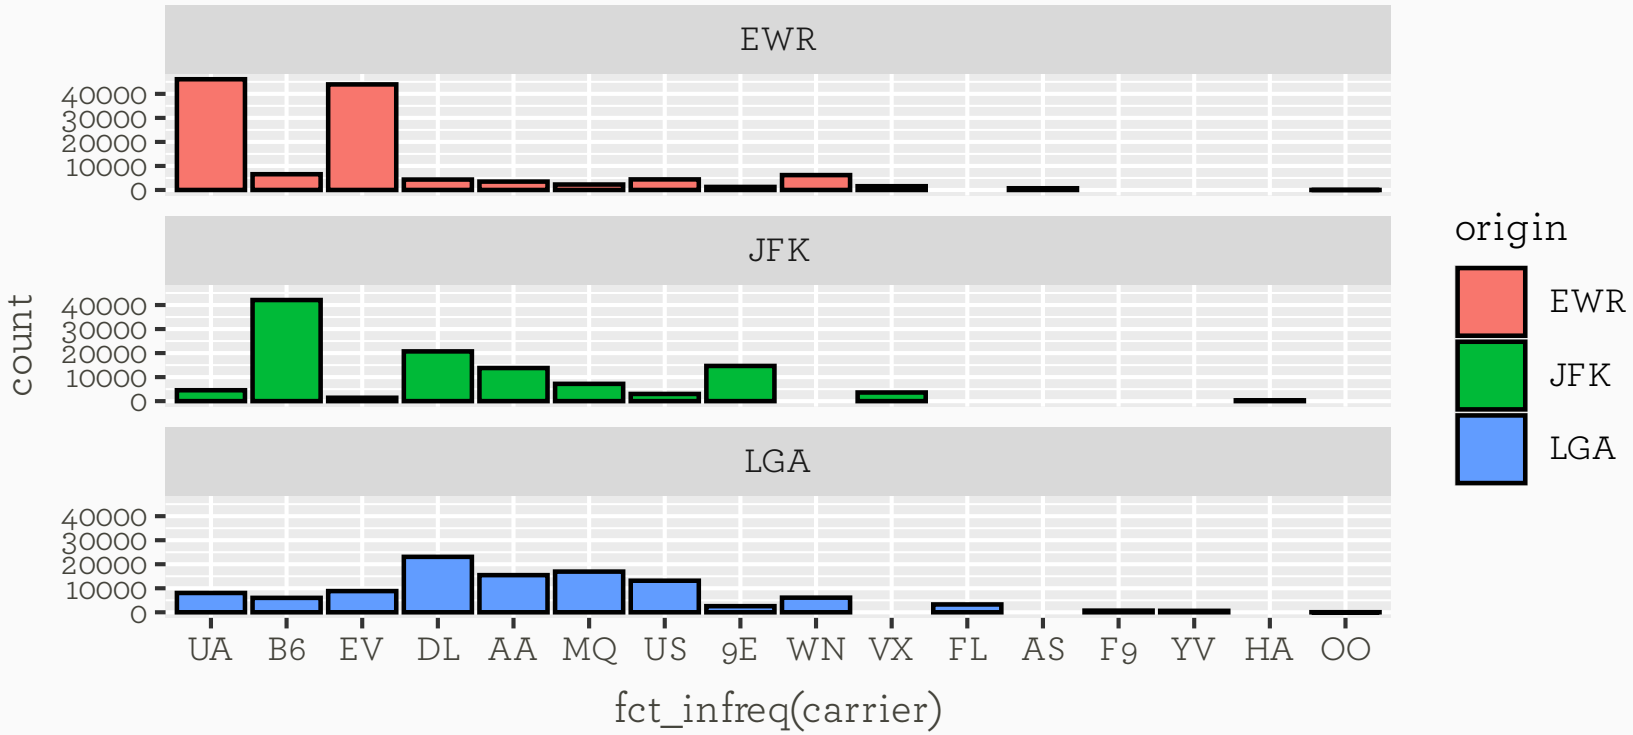

7. Les diagrammes bâtons

Comparer 2 variables catégorielles

Selon les types d'objets géométriques de vos graphiques, les choix possibles sont :

- "`stacked`"
- "`identity`"
- "`dodge`"
- "`fill`"
- "`jitter`"

Visualisation : 8. Systèmes de coordonnées

8. Système de coordonnées

Les systèmes de coordonnées sont probablement l'une des parties les plus compliquées de `ggplot2`.

Par défaut, le système de coordonnées cartésiennes est utilisé. Les axes x et y agissent indépendamment pour déterminer la position de chaque point.

D'autres systèmes existent. Examinons les plus utiles :

- `coord_cartesian()`
- `coord_flip()`
- `coord_map()`, `coord_quickmap()`
- `coord_polar()`

8. Système de coordonnées

coord_flip()

`coord_flip()` inverse la position des axes x et y :

```
# Gauche
ggplot(data = mpg, mapping = aes(x = class, y = hwy)) + geom_boxplot()
```

```
# Droite
ggplot(data = mpg, mapping = aes(x = class, y = hwy)) + geom_boxplot() +
  coord_flip()
```

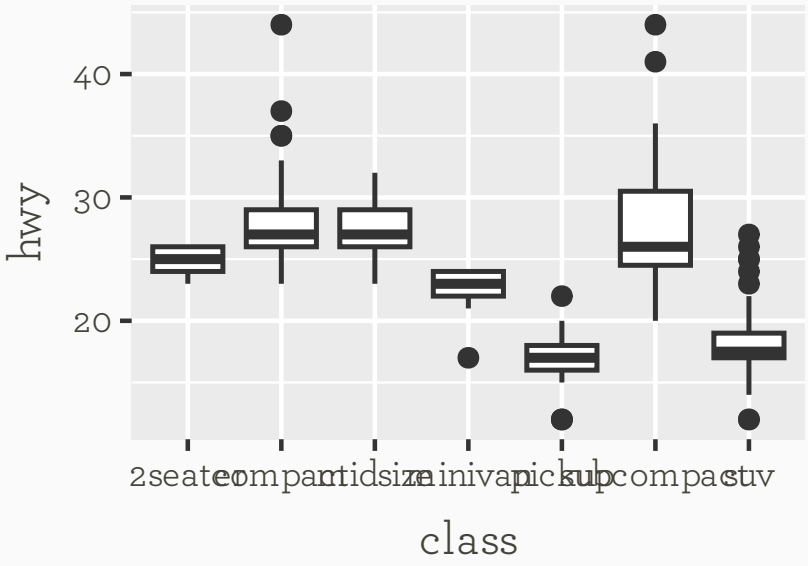

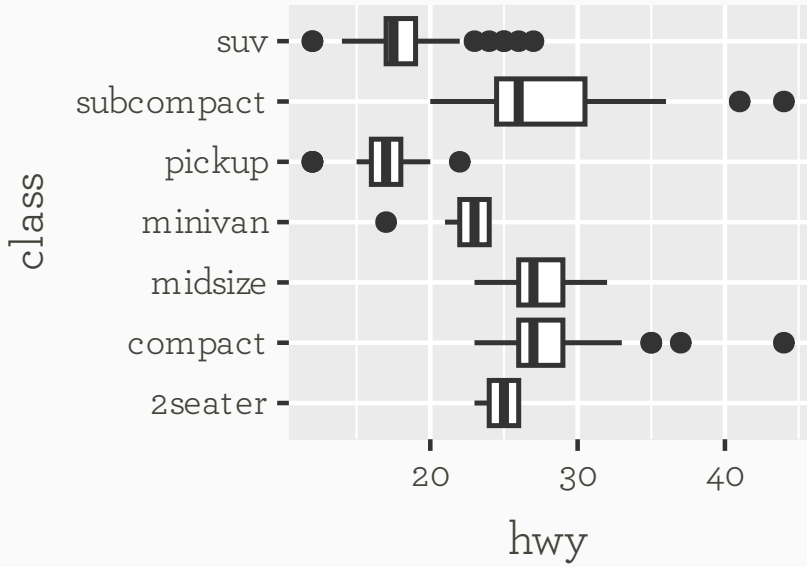

8. Système de coordonnées

coord_map(), coord_quickmap()

coord_map() ou coord_quickmap() sont utiles pour... faire des cartes !

```
fr <- map_data("france")

ggplot(fr, aes(long, lat, group = group)) + geom_polygon()
```

```
ggplot(fr, aes(long, lat, group = group)) + geom_polygon() + coord_map()
```

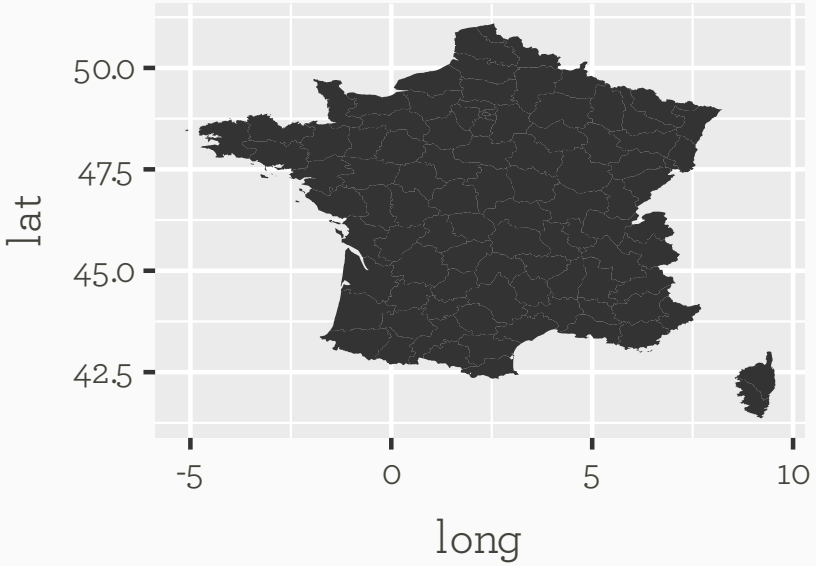

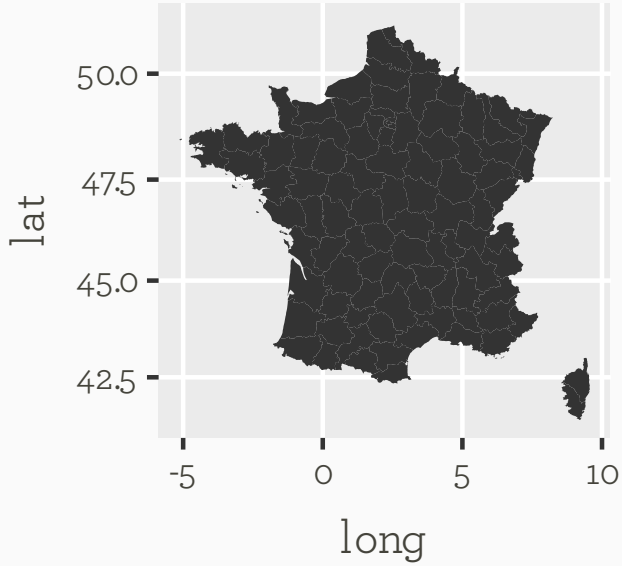

8. Système de coordonnées

coord_polar()

`coord_polar()` permet d'utiliser des coordonnées polaires. Il exise un lien entre barplot et graphique de Coxcomb.

Tapez les commandes suivantes pour visualiser ce lien :

```
bar <- ggplot(data = diamonds) +
  geom_bar(
    mapping = aes(x = cut, fill = cut),
    show.legend = FALSE,
    width = 1
  ) +
  theme(aspect.ratio = 1) +
  labs(x = NULL, y = NULL)
```

8. Système de coordonnées

coord_polar()

`coord_polar()` permet d'utiliser des coordonnées polaires. Il exise un lien entre barplot et graphique de Coxcomb.

Tapez les commandes suivantes pour visualiser ce lien :

```
bar                     # Gauche
bar + coord_flip()      # Milieu
bar + coord_polar()     # Droite
```

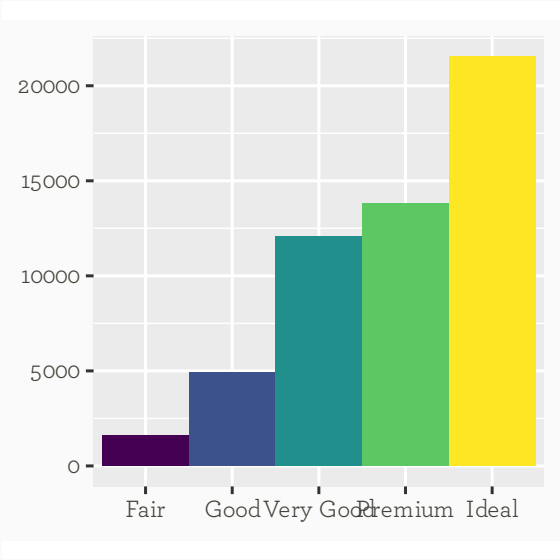

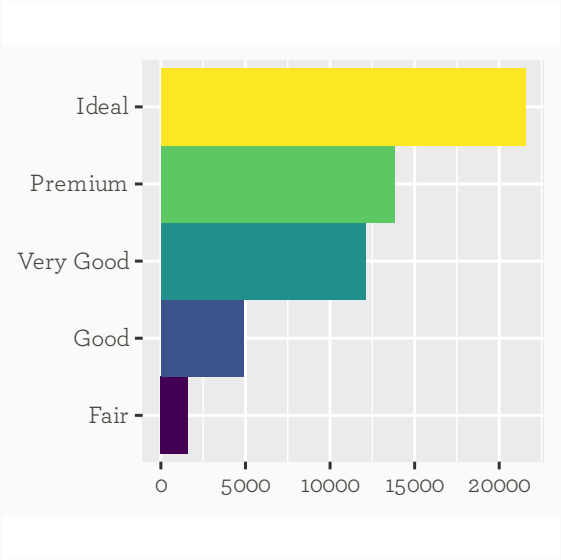

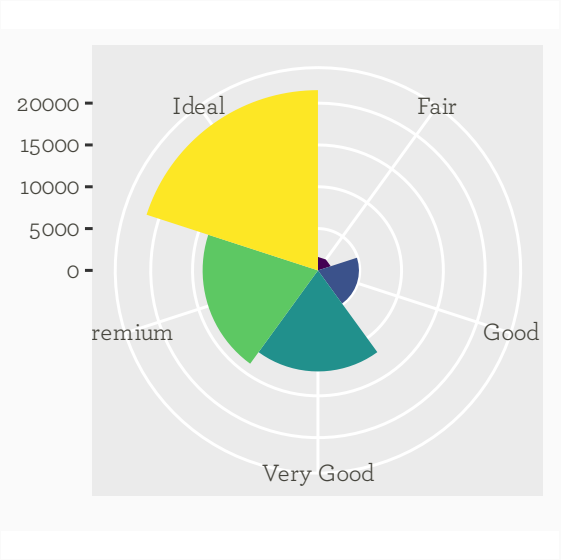

8. Système de coordonnées

coord_polar()

`coord_polar()` permet d'utiliser des coordonnées polaires. Il exise aussi un lien entre barplot empilé et digramme camembert.

Tapez les commandes suivantes pour visualiser ce lien :

```
pie <- ggplot(mpg, aes(x = factor(1), fill = factor(cyl))) +
    geom_bar(width=1)

pie                                  # Gauche
pie + coord_polar()                  # Milieu
pie + coord_polar(theta = "y")       # Droite
```

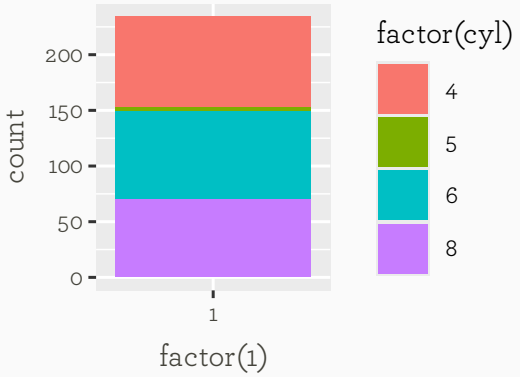

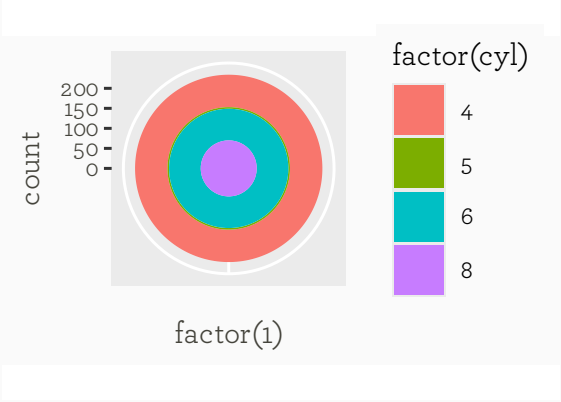

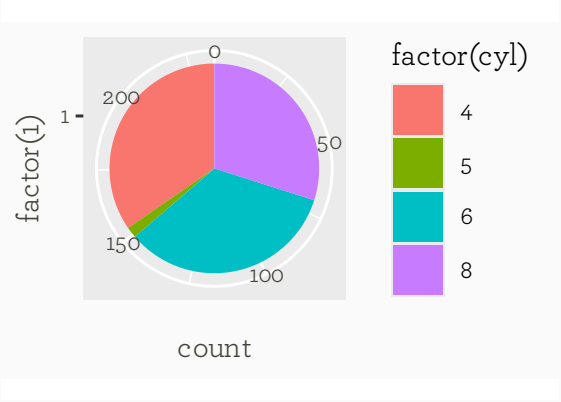

8. Système de coordonnées

Exercices

- Que nous apprend le graphique ci-dessous au sujet de la relation entre consommation en ville (`cty`) et consommation sur autoroute (`hwy`)[2] ?
- Pourquoi est-il important d'utiliser `coord_fixed()` ?
- Que fait `geom_abline()` ?

```
ggplot(data = mpg,
       aes(x = cty, y = hwy)) +
  geom_point(size = 0.7,
             alpha = 0.5) +
  geom_abline() +
  coord_fixed()
```

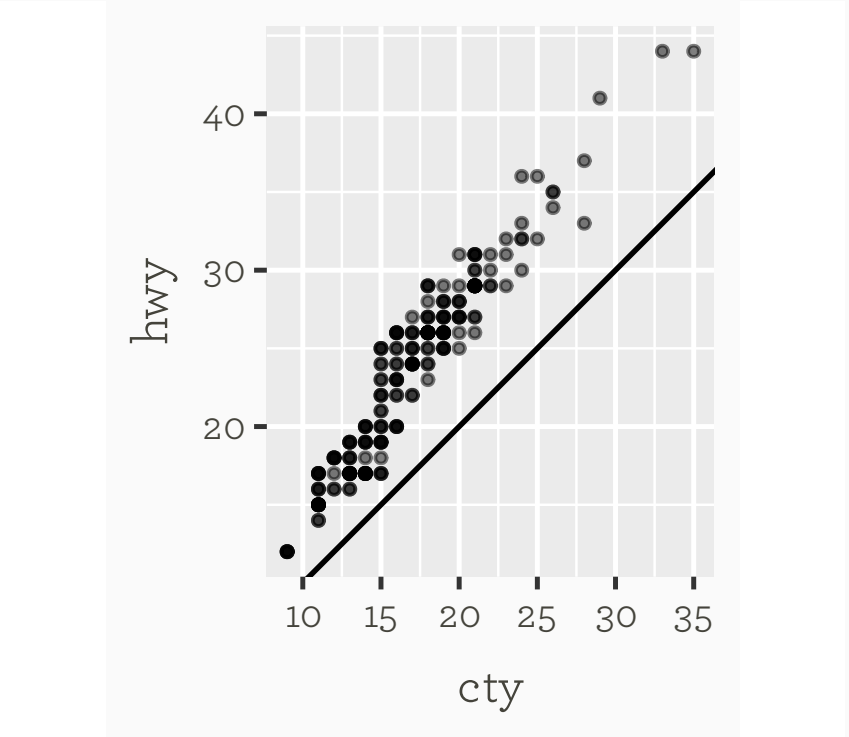

2. Consultez l'aide de `mpg` pour savoir de quoi nous parlons.

Visualisation : 9. Des graphiques présentables...

9. Des graphiques présentables

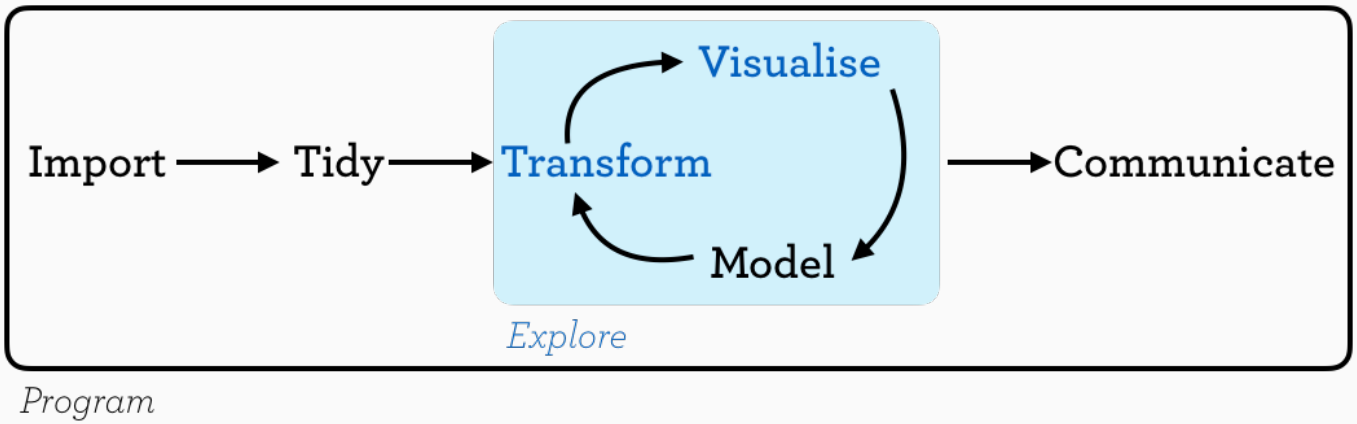

Jusqu'à maintenant, nous avons fait des graphiques pour explorer des jeux de données.

Il est tout aussi important d'être capable de réaliser des graphiques pour communiquer des résultats.

Pour cela, nous sommes souvent amenés à modifier l'apparence de nos graphiques. Nous aurons besoin des packages `ggrepel` et `viridis`. Installez-les dès maintenant.

9. Des graphiques présentables

Pour mettre en forme un graphique afin de communiquer clairement des résultats, il faut maîtriser au minimum les 3 éléments suivants :

1. Les labels avec la fonction `labs()`.
2. Les échelles avec notamment les fonctions `scale_XXX_YYY()`.
3. Les thèmes avec les fonctions `theme_XX()`.

Nous allons voir ensemble comment ça marche en reprenant des exemples de graphiques créés précédemment.